

HỌC VIỆN CÔNG NGHỆ BƯU CHÍNH VIỄN THÔNG



Trần Quang Ninh

**ỨNG DỤNG LLM VÀ RAG TRONG XÂY DỰNG NỀN
TẢNG GỢI Ý DU LỊCH CÁ NHÂN HÓA TẠI VIỆT NAM**

CHUYÊN NGÀNH : HỆ THỐNG THÔNG TIN

MÃ SỐ : 8.48.01.04

BÁO CÁO THỰC TẬP TỐT NGHIỆP
(Theo định hướng ứng dụng)

NGƯỜI HƯỚNG DẪN KHOA HỌC: PGS.TS. TRẦN ĐÌNH QUẾ

HÀ NỘI – 2026

MỤC LỤC

DANH MỤC BẢNG.....	4
DANH MỤC HÌNH.....	5
DANH MỤC CHỮ CÁI VIẾT TẮT.....	6
MỞ ĐẦU.....	8
1. Lý do chọn đề tài.....	8
2. Tổng quan về vấn đề nghiên cứu.....	9
2.1. Giới thiệu lĩnh vực nghiên cứu.....	9
2.2. Các hướng tiếp cận chính.....	9
2.3. Khoảng trống nghiên cứu và vấn đề đặt ra.....	9
3. Mục đích nghiên cứu.....	10
3.1. Mục tiêu tổng quát.....	10
3.2. Mục tiêu cụ thể.....	10
4. Đối tượng và phạm vi nghiên cứu.....	11
4.1. Đối tượng nghiên cứu.....	11
4.2. Phạm vi nghiên cứu.....	11
5. Phương pháp nghiên cứu.....	12
NỘI DUNG.....	14
Chương 1: CƠ SỞ LÝ LUẬN.....	14
1.1. Tổng quan về hệ thống gợi ý.....	14
1.2. Cá nhân hóa trong lĩnh vực du lịch.....	14
1.3. Mô hình ngôn ngữ lớn (LLM).....	15
1.3.1. Khái niệm.....	15
1.3.2. Các mô hình tiêu biểu.....	15
1.3.3. Hạn chế.....	17
1.4. Retrieval-Augmented Generation (RAG).....	17
1.4.1. Khái niệm.....	17
1.4.2. Kiến trúc và quy trình hoạt động.....	18
1.4.3. Vai trò của RAG trong hệ thống ứng dụng LLM.....	19
1.4.4. Ưu điểm và hạn chế.....	20
1.5. Hybrid Search và Reranking.....	21
1.5.1. Hybrid Search.....	21
1.5.2. Reranking.....	22
1.6. Các nghiên cứu và hệ thống liên quan.....	22
1.6.1. Các nền tảng du lịch truyền thống.....	22
1.6.2. Các hệ thống tích hợp LLM.....	23
1.6.3. Khoảng trống nghiên cứu.....	24
1.7. Kết luận chương 1.....	25

Chương 2: PHÂN TÍCH BÀI TOÁN VÀ THIẾT KẾ NỀN TẢNG.....	26
2.1. Phân tích bài toán.....	26
2.1.1. Mô tả bài toán và người dùng.....	26
2.1.2. Yêu cầu chức năng.....	27
2.1.3. Yêu cầu phi chức năng.....	28
2.2. Kiến trúc hệ thống.....	30
2.2.1. Kiến trúc tổng thể.....	30
2.2.2. Luồng xử lý.....	32
2.2.3. Công nghệ sử dụng.....	35
2.3. Thiết kế dữ liệu và kho tri thức.....	37
2.3.1. Cơ sở dữ liệu quan hệ.....	37
2.3.2. Cơ sở dữ liệu vector (pgvector).....	41
2.3.3. Kho tri thức.....	42
2.3.4. Quy trình xử lý dữ liệu.....	43
2.4. Thiết kế hệ thống RAG.....	44
2.4.1. RAG cơ bản và RAG nâng cao.....	44
2.4.2. Phân tích truy vấn và quản lý ngữ cảnh.....	46
2.4.3. Truy xuất tri thức.....	47
2.4.4. Tối ưu ngữ cảnh.....	49
2.4.5. Sinh phản hồi và cá nhân hóa.....	50
2.4.6. Hậu xử lý.....	52
2.5. Kết luận chương 2.....	53
Chương 3: THỰC NGHIỆM VÀ ĐÁNH GIÁ KẾT QUẢ.....	55
3.1. Thiết lập thực nghiệm.....	55
3.1.1. Mục tiêu và phương pháp.....	55
3.1.2. Môi trường thực nghiệm và cấu hình đánh giá.....	56
3.1.3. Bộ dữ liệu thực nghiệm.....	57
3.1.4. Kịch bản thực nghiệm.....	58
3.2. Xây dựng hệ thống thực nghiệm.....	59
3.2.1. Tổng quan các thành phần triển khai.....	59
3.2.2. Một số điểm triển khai đáng chú ý.....	60
3.2.3. Kết quả đầu ra của hệ thống.....	61
3.3. Kết quả và đánh giá.....	62
3.3.1. Đánh giá phân tích truy vấn người dùng.....	62
3.3.2. Đánh giá chất lượng lộ trình end-to-end.....	63
3.3.3. So sánh các cấu hình RAG.....	66
3.3.4. Đánh giá khả năng cá nhân hóa.....	67
3.3.5. Tổng hợp kết quả đánh giá.....	68

3.4. Kết luận chương 3.....	69
KẾT LUẬN.....	71
DANH MỤC CÁC TÀI LIỆU THAM KHẢO.....	72

DANH MỤC BẢNG

Bảng 1.1. Ưu điểm và hạn chế của RAG.....	20
Bảng 1.2. Một số nền tảng du lịch thương mại tiêu biểu.....	22
Bảng 1.3. Một số nghiên cứu ứng dụng LLM trong gợi ý và lập kế hoạch.....	23
Bảng 2.1. Yêu cầu chức năng của hệ thống.....	27
Bảng 2.2. Yêu cầu phi chức năng của hệ thống.....	29
Bảng 2.4. Các bảng dữ liệu chính trong hệ thống.....	40
Bảng 2.5. Cấu trúc dữ liệu vector embedding.....	41
Bảng 2.6. So sánh RAG cơ bản và RAG nâng cao trong hệ thống.....	45
Bảng 2.7. Chiến lược truy xuất của RAG Planner.....	47
Bảng 2.8. Cấu trúc đầu ra của hệ thống.....	51
Bảng 2.9. Các tiêu chí đánh giá chất lượng.....	52
Bảng 3.2. Môi trường phân cứng và phần mềm.....	56
Bảng 3.3. Cấu hình mô hình và hệ thống RAG.....	57
Bảng 3.4. Thống kê dữ liệu kho tri thức.....	57
Bảng 3.5. Kịch bản thực nghiệm.....	58
Bảng 3.6. Thành phần triển khai trong hệ thống thực nghiệm.....	59
Bảng 3.7. Thành phần kết quả đầu ra.....	61
Bảng 3.8. Kết quả đánh giá phân tích truy vấn.....	63
Bảng 3.9. Kết quả đánh giá lịch trình theo ràng buộc đầu vào.....	64
Bảng 3.10. Kết quả so sánh các cấu hình RAG.....	66
Bảng 3.11. So sánh kết quả có và không có cá nhân hóa.....	67
Bảng 3.12. Tổng hợp kết quả theo bốn kịch bản thực nghiệm.....	68
Bảng 3.13. Tổng hợp thời gian phản hồi của hệ thống.....	68

DANH MỤC HÌNH

Hình 1.1. Kiến trúc tổng quát của hệ thống RAG.....	18
Hình 2.1. Kiến trúc tổng quát của hệ thống.....	30
Hình 2.2. Luồng xử lý chính của hệ thống.....	32
Hình 2.3a. Sơ đồ ERD nhóm bảng người dùng, hội thoại và lộ trình.....	37
Hình 2.3b. Sơ đồ ERD nhóm bảng dữ liệu du lịch.....	38
Hình 2.4. Quy trình xử lý dữ liệu.....	44
Hình 2.5. Kiến trúc Query Understanding & Memory.....	46
Hình 2.6. Kiến trúc giai đoạn Retrieval.....	48
Hình 2.7. Quy trình tối ưu ngữ cảnh.....	49
Hình 2.8. Giai đoạn Generation & Personalization.....	50
Hình 2.9. Quy trình hậu xử lý kết quả.....	52
Hình 3.1. Giao diện hội thoại.....	62

DANH MỤC CHỮ CÁI VIẾT TẮT

Từ viết tắt	Tiếng Anh	Nghĩa tiếng Việt
AI	Artificial Intelligence	Trí tuệ nhân tạo
API	Application Programming Interface	Giao diện lập trình ứng dụng
BERT	Bidirectional Encoder Representations from Transformers	Mô hình biểu diễn mã hóa hai chiều dựa trên Transformer
BM25	Best Matching 25	Thuật toán xếp hạng tìm kiếm từ khóa
CPU	Central Processing Unit	Bộ xử lý trung tâm
ERD	Entity-Relationship Diagram	Sơ đồ thực thể – mối quan hệ
GPT	Generative Pre-trained Transformer	Mô hình Transformer tiền huấn luyện sinh văn bản
GPU	Graphics Processing Unit	Bộ xử lý đồ họa
LLM	Large Language Model	Mô hình ngôn ngữ lớn
LSTM	Long Short-Term Memory	Bộ nhớ dài-ngắn hạn
MLM	Masked Language Modeling	Mô hình hóa ngôn ngữ che giấu
NLI	Natural Language Inference	Suy luận ngôn ngữ tự nhiên
NLP	Natural Language Processing	Xử lý ngôn ngữ tự nhiên
NLU	Natural Language Understanding	Hiểu ngôn ngữ tự nhiên
NSP	Next Sentence Prediction	Dự đoán câu tiếp theo
OSRM	Open Source Routing Machine	Máy định tuyến mã nguồn mở
POI	Point of Interest	Điểm quan tâm

RAG	Retrieval-Augmented Generation	Sinh nội dung tăng cường bằng truy xuất
RAGAS	Retrieval-Augmented Generation Assessment	Khung đánh giá hệ thống RAG
RAM	Random Access Memory	Bộ nhớ truy cập ngẫu nhiên
REST	Representational State Transfer	Kiến trúc truyền trạng thái đại diện
RNN	Recurrent Neural Network	Mạng nơ-ron hồi quy
RRF	Reciprocal Rank Fusion	Hợp nhất xếp hạng nghịch đảo
SQL	Structured Query Language	Ngôn ngữ truy vấn có cấu trúc
SSE	Server-Sent Events	Sự kiện gửi từ máy chủ
TPU	Tensor Processing Unit	Bộ xử lý tensor
UI	User Interface	Giao diện người dùng

MỞ ĐẦU

1. Lý do chọn đề tài

Trong những năm gần đây, ngành du lịch Việt Nam phát triển mạnh mẽ với sự đa dạng về điểm đến, loại hình dịch vụ và nhu cầu trải nghiệm của du khách. Quá trình chuyển đổi số đã thúc đẩy mạnh mẽ sự ra đời của các nền tảng trực tuyến hỗ trợ người dùng tìm kiếm thông tin du lịch, đặt phòng khách sạn, vé máy bay và xây dựng kế hoạch chuyến đi. Tuy nhiên, phần lớn các hệ thống hiện nay mới chỉ cung cấp thông tin theo dạng tra cứu hoặc gợi ý dựa trên các tiêu chí đơn giản, chưa thực sự đáp ứng được nhu cầu cá nhân hóa ngày càng cao của người dùng.

Việc xây dựng một lịch trình du lịch cá nhân đòi hỏi du khách phải tự thu thập và xử lý khối lượng thông tin từ các nguồn dữ liệu khác nhau. Quá trình thủ công này tiêu tốn rất nhiều thời gian mà còn chưa thực sự hiệu quả, do kết quả thu được thường khó có thể đáp ứng được đồng thời về sở thích, ngân sách và quỹ thời gian của từng cá nhân.

Sự phát triển mạnh mẽ của các mô hình ngôn ngữ lớn (Large Language Models - LLM) đã mở ra khả năng tạo nội dung và tương tác tự nhiên giữa hệ thống với người dùng. Tuy nhiên, các mô hình này vẫn còn tồn tại rất nhiều hạn chế về tính cập nhật và độ chính xác của dữ liệu. Trong khi đó, kỹ thuật Retrieval-Augmented Generation (RAG) cho phép kết hợp khả năng suy luận của LLM với nguồn tri thức bên ngoài, giúp nâng cao chất lượng và độ tin cậy của câu trả lời.

Xuất phát từ những vấn đề trên, việc nghiên cứu và xây dựng hệ thống gợi ý lộ trình du lịch cá nhân hóa tại Việt Nam dựa trên sự kết hợp giữa RAG và LLM có ý nghĩa cả về mặt khoa học lẫn thực tiễn. Đề tài không chỉ góp phần ứng dụng các công nghệ trí tuệ nhân tạo hiện đại vào lĩnh vực du lịch mà còn tạo nền tảng cho các hệ thống hỗ trợ ra quyết định thông minh trong tương lai.

2. Tổng quan về vấn đề nghiên cứu

2.1. Giới thiệu lĩnh vực nghiên cứu

Hệ thống gợi ý (Recommendation System) là một trong những lĩnh vực nghiên cứu quan trọng của trí tuệ nhân tạo và khoa học dữ liệu, được ứng dụng rộng rãi trong đa dạng lĩnh vực như thương mại điện tử, giải trí, giáo dục và du lịch. Trong lĩnh vực du lịch, hệ thống gợi ý đóng vai trò hỗ trợ người dùng lựa chọn điểm đến, địa điểm tham quan, cơ sở lưu trú hoặc xây dựng lịch trình phù hợp với nhu cầu cá nhân.

Cùng với sự phát triển của các LLM và các kỹ thuật RAG hiện đại, xu hướng xây dựng các hệ thống gợi ý có khả năng tương tác bằng ngôn ngữ tự nhiên đang ngày càng được quan tâm. Điều này mở ra khả năng phát triển các nền tảng du lịch thông minh có thể hiểu nhu cầu của người dùng, khai thác tri thức từ nhiều nguồn dữ liệu khác nhau và đưa ra các gợi ý mang tính cá nhân hóa cao.

2.2. Các hướng tiếp cận chính

Phương pháp gợi ý truyền thống: các phương pháp khai thác thông tin về địa điểm hoặc lịch sử tương tác của người dùng để đưa ra đề xuất phù hợp như lọc cộng tác (Collaborative Filtering), lọc dựa trên nội dung (Content-Based Filtering).

Phương pháp học máy và học sâu: khai thác khả năng tự học đặc trưng từ dữ liệu người dùng và dữ liệu du lịch.

Nghiên cứu ứng dụng LLM kết hợp với RAG: tập trung khai thác khả năng hiểu ngôn ngữ tự nhiên của LLM và khả năng truy xuất thông tin từ cơ sở tri thức thông qua kiến trúc RAG.

2.3. Khoảng trống nghiên cứu và vấn đề đặt ra

Mặc dù đã có nhiều nghiên cứu về hệ thống gợi ý du lịch cũng như các giải pháp ứng dụng LLM và RAG, phần lớn các công trình hiện nay chỉ tập trung vào từng thành phần riêng lẻ của bài toán. Các hệ thống gợi ý truyền thống còn hạn chế trong việc xử lý các yêu cầu được diễn đạt bằng ngôn ngữ tự nhiên, trong khi các hệ thống sử dụng LLM đơn thuần chưa đảm bảo tốt tính chính xác và khả năng cập nhật thông tin.

Bên cạnh đó, các nghiên cứu ứng dụng RAG chủ yếu được triển khai trong các hệ thống hỏi đáp hoặc truy xuất tri thức tổng quát mà chưa tập trung nhiều vào bài toán gợi ý du lịch mang tính cá nhân hóa. Đối với dữ liệu du lịch tại Việt Nam, số lượng nghiên cứu kết hợp đồng thời LLM, RAG và các kỹ thuật cá nhân hóa vẫn còn hạn chế. Do đó, việc nghiên cứu và xây dựng một nền tảng gợi ý du lịch mang tính cá nhân hóa dựa trên sự kết hợp giữa LLM và kiến trúc RAG là cần thiết, góp phần nâng cao chất lượng tư vấn và khả năng đáp ứng nhu cầu đa dạng của du khách trong bối cảnh du lịch số hiện nay.

3. Mục đích nghiên cứu

3.1. Mục tiêu tổng quát

Mục tiêu tổng quát của đề tài là nghiên cứu và ứng dụng LLM kết hợp với kiến trúc RAG nhằm xây dựng nền tảng gợi ý du lịch cá nhân hóa tại Việt Nam. Hệ thống được đề xuất hướng tới khả năng tiếp nhận và phân tích nhu cầu của người dùng dưới dạng ngôn ngữ tự nhiên, khai thác tri thức từ cơ sở dữ liệu du lịch và cung cấp các gợi ý phù hợp với đặc điểm, sở thích và nhu cầu riêng của từng cá nhân.

3.2. Mục tiêu cụ thể

- Nghiên cứu cơ sở lý thuyết về hệ thống gợi ý, LLM, kiến trúc RAG và các phương pháp cá nhân hóa trong hệ thống gợi ý nhằm xây dựng nền tảng khoa học cho bài toán nghiên cứu.
- Khảo sát và xây dựng cơ sở tri thức về du lịch Việt Nam từ các nguồn dữ liệu phù hợp, phục vụ cho quá trình truy xuất thông tin và hỗ trợ tạo phản hồi của hệ thống.
- Đề xuất kiến trúc nền tảng gợi ý du lịch cá nhân hóa dựa trên sự kết hợp giữa LLM và cơ chế RAG, cho phép hệ thống hiểu yêu cầu của người dùng, truy xuất thông tin liên quan và đưa ra các gợi ý phù hợp.
- Xây dựng và triển khai thử nghiệm hệ thống nhằm đánh giá khả năng ứng dụng của giải pháp đề xuất trong việc tư vấn điểm đến, đề xuất hoạt động du lịch và hỗ trợ xây dựng lịch trình theo nhu cầu cá nhân.

- Đánh giá hiệu quả của hệ thống thông qua các tiêu chí liên quan đến chất lượng truy xuất thông tin, độ phù hợp của kết quả gợi ý và khả năng đáp ứng nhu cầu của người dùng.

4. Đối tượng và phạm vi nghiên cứu

4.1. Đối tượng nghiên cứu

Đối tượng nghiên cứu của luận văn là các phương pháp truy xuất và khai thác tri thức phục vụ bài toán gợi ý, các LLM trong xử lý ngôn ngữ tự nhiên, cùng các kỹ thuật cá nhân hóa dựa trên đặc trưng và nhu cầu của người dùng. Bên cạnh đó, nghiên cứu cũng xem xét việc tổ chức và biểu diễn dữ liệu du lịch dưới dạng cơ sở tri thức nhằm phục vụ quá trình tìm kiếm và cung cấp thông tin.

4.2. Phạm vi nghiên cứu

Luận văn tập trung nghiên cứu cơ chế kết hợp giữa mô hình ngôn ngữ và hệ thống truy xuất tri thức trong bài toán hỗ trợ ra quyết định du lịch. Nội dung nghiên cứu hướng đến việc khai thác dữ liệu du lịch để cung cấp thông tin và đề xuất phù hợp với từng nhóm người dùng. Các hoạt động liên quan đến giao dịch thương mại điện tử, quản trị doanh nghiệp du lịch hoặc vận hành dịch vụ không thuộc phạm vi của đề tài.

Nguồn dữ liệu được sử dụng trong nghiên cứu bao gồm các thông tin về điểm đến, địa danh du lịch, cơ sở lưu trú, dịch vụ ăn uống, hoạt động trải nghiệm và các nội dung liên quan đến du lịch Việt Nam được thu thập từ các nguồn công khai. Dữ liệu được lựa chọn và xử lý nhằm phục vụ mục đích nghiên cứu, thử nghiệm và đánh giá giải pháp đề xuất.

Nghiên cứu được thực hiện trên tập dữ liệu phản ánh các địa điểm và dịch vụ du lịch trong lãnh thổ Việt Nam. Các kết quả thực nghiệm được xây dựng và đánh giá trong bối cảnh du lịch nội địa nhằm đảm bảo tính phù hợp với mục tiêu nghiên cứu.

Các nội dung nghiên cứu, xây dựng và đánh giá được thực hiện trong thời gian triển khai luận văn. Dữ liệu sử dụng cho thực nghiệm được thu thập trong giai đoạn nghiên cứu và không xem xét yếu tố biến động theo thời gian thực.

5. Phương pháp nghiên cứu

Luận văn được thực hiện theo phương pháp nghiên cứu kết hợp giữa nghiên cứu lý thuyết và thực nghiệm nhằm xây dựng và đánh giá giải pháp hỗ trợ gợi ý du lịch cá nhân hóa dựa trên mô hình ngôn ngữ lớn và kỹ thuật truy xuất tri thức.

- Nghiên cứu cơ sở lý thuyết
 - + Thu thập, tổng hợp và phân tích các tài liệu khoa học liên quan đến hệ thống gợi ý, LLM, RAG, cơ sở dữ liệu vector và các phương pháp cá nhân hóa.
 - + Khảo sát các công trình nghiên cứu trong và ngoài nước nhằm xác định các hướng tiếp cận hiện có, những hạn chế còn tồn tại và khoảng trống nghiên cứu cần giải quyết.
- Thu thập và xây dựng dữ liệu
 - + Thu thập dữ liệu du lịch từ các nguồn công khai như cổng thông tin du lịch, website giới thiệu điểm đến, dữ liệu địa danh, cơ sở lưu trú, nhà hàng và các hoạt động trải nghiệm.
 - + Chuẩn hóa và làm sạch dữ liệu nhằm loại bỏ thông tin trùng lặp, thiếu nhất quán hoặc không còn giá trị sử dụng.
 - + Tổ chức dữ liệu dưới dạng cơ sở tri thức phục vụ quá trình lưu trữ, truy xuất và khai thác thông tin.
- Xây dựng hệ thống truy xuất tri thức
 - + Chuyển đổi dữ liệu văn bản sang biểu diễn vector thông qua các mô hình embedding phù hợp.
 - + Lưu trữ dữ liệu trên cơ sở dữ liệu vector để hỗ trợ tìm kiếm ngữ nghĩa.
 - + Thiết kế cơ chế truy xuất thông tin dựa trên mức độ liên quan giữa câu truy vấn và dữ liệu trong cơ sở tri thức.
- Xây dựng mô hình thực nghiệm
 - + Tích hợp mô hình ngôn ngữ lớn với hệ thống truy xuất tri thức theo kiến trúc RAG.
 - + Xây dựng cơ chế tiếp nhận và phân tích yêu cầu của người dùng dưới dạng ngôn ngữ tự nhiên.

- + Thiết kế quy trình sinh gợi ý dựa trên thông tin truy xuất được và đặc điểm của người dùng.
- + Triển khai hệ thống trên môi trường thử nghiệm phục vụ đánh giá.
- Đánh giá hệ thống
 - + Thực hiện các kịch bản thử nghiệm với nhiều nhóm yêu cầu du lịch khác nhau.
 - + Đánh giá chất lượng truy xuất thông tin thông qua các chỉ số RAGAS gồm: Context Relevance, Faithfulness, và Answer Relevancy.
 - + Đánh giá chất lượng phản hồi của hệ thống dựa trên mức độ liên quan, tính chính xác và khả năng đáp ứng nhu cầu người dùng.
 - + So sánh kết quả giữa mô hình có sử dụng cơ chế truy xuất tri thức và mô hình chỉ sử dụng LLM nhằm xác định hiệu quả của giải pháp đề xuất.
- Công cụ và môi trường nghiên cứu
 - + Ngôn ngữ lập trình: Python.
 - + Mô hình ngôn ngữ lớn: lựa chọn một trong các mô hình mã nguồn mở hoặc dịch vụ LLM phù hợp với yêu cầu nghiên cứu.
 - + Mô hình embedding phục vụ biểu diễn dữ liệu ngữ nghĩa.
 - + Cơ sở dữ liệu vector phục vụ lưu trữ và truy xuất tri thức.
 - + Môi trường phát triển và thực nghiệm: Visual Studio Code hoặc các nền tảng tương đương.

NỘI DUNG

Chương 1: CƠ SỞ LÝ LUẬN

1.1. Tổng quan về hệ thống gợi ý

Ngày nay, trong bối cảnh lượng thông tin trên Internet tăng nhanh, người dùng thường gặp khó khăn khi lựa chọn nội dung phù hợp. Hệ thống gợi ý được phát triển nhằm hỗ trợ ra quyết định, giúp lọc thông tin và đưa ra đề xuất cá nhân hóa dựa trên dữ liệu tương tác, hành vi và đặc điểm người dùng [16].

Hiện nay, hệ thống gợi ý được ứng dụng rộng rãi trong thương mại điện tử, giải trí, mạng xã hội và du lịch. Các phương pháp phổ biến gồm lọc cộng tác (Collaborative Filtering), lọc dựa trên nội dung (Content-Based Filtering) và mô hình lai (Hybrid) [16]. Ngoài ra, học sâu cũng được áp dụng để cải thiện khả năng biểu diễn và dự đoán. Tuy nhiên, các phương pháp truyền thống vẫn gặp hạn chế như dữ liệu thưa, vấn đề người dùng mới, thiếu khả năng giải thích và khó thích ứng với thay đổi nhu cầu [16].

Sự phát triển của LLM mở ra hướng tiếp cận mới cho hệ thống gợi ý, đặc biệt trong các bài toán yêu cầu phân tích yêu cầu bằng ngôn ngữ tự nhiên và tạo phản hồi linh hoạt theo ngữ cảnh [2]. Việc tích hợp LLM vào hệ thống gợi ý giúp tăng khả năng tương tác, giải thích và cá nhân hóa đề xuất [6]. Tuy nhiên, để giảm phụ thuộc vào tri thức nội tại của mô hình và hỗ trợ khai thác thông tin từ các nguồn dữ liệu bên ngoài, LLM thường được kết hợp với các kỹ thuật như RAG [7]. Trong lĩnh vực du lịch, hướng tiếp cận này đặc biệt phù hợp do nhu cầu của người dùng rất đa dạng, phụ thuộc nhiều vào ngữ cảnh cá nhân và thông tin du lịch thường phân tán trên nhiều nguồn khác nhau.

1.2. Cá nhân hóa trong lĩnh vực du lịch

Tại Việt Nam, du lịch được xác định là lĩnh vực quan trọng trong định hướng phát triển đến năm 2030, với yêu cầu nâng cao chất lượng dịch vụ và khả năng đáp ứng nhu cầu ngày càng đa dạng của du khách [1]. Trong bối cảnh đó, cá nhân hóa trở thành một yêu cầu quan trọng đối với các hệ thống hỗ trợ tìm kiếm, lựa chọn và lập kế hoạch du lịch.

Khác với nhiều lĩnh vực khác, nhu cầu du lịch phụ thuộc đồng thời vào nhiều yếu tố như sở thích cá nhân, ngân sách, thời gian, số lượng thành viên, mục đích chuyến đi và điều kiện di chuyển. Dưới góc độ hệ thống gợi ý, các yếu tố này có thể được sử dụng để mô hình hóa nhu cầu người dùng và đưa ra đề xuất phù hợp hơn [16]. Vì vậy, cá nhân hóa trong du lịch không chỉ là gợi ý địa điểm, mà còn cần hỗ trợ xây dựng lịch trình có tính khả thi, phù hợp với thời gian, chi phí và ngữ cảnh của từng người dùng [19].

Bên cạnh đó, thông tin du lịch thường phân tán trên nhiều nguồn như website, blog, diễn đàn, bản đồ số và nền tảng đánh giá. Người dùng phải tự tổng hợp và so sánh thông tin trước khi ra quyết định, dẫn đến mất nhiều thời gian và dễ bị quá tải. Do đó, một hệ thống gợi ý du lịch hiệu quả cần có khả năng hiểu nhu cầu người dùng, khai thác thông tin từ nhiều nguồn và tạo ra đề xuất cá nhân hóa phù hợp với bối cảnh du lịch Việt Nam.

1.3. Mô hình ngôn ngữ lớn (LLM)

1.3.1. Khái niệm

LLM là nhóm mô hình học sâu được thiết kế để hiểu và sinh ngôn ngữ tự nhiên thông qua quá trình huấn luyện trên khối lượng dữ liệu văn bản lớn [2]. Kiến trúc nền tảng của hầu hết LLM hiện đại dựa trên Transformer [18], cho phép mô hình đánh giá mức độ liên quan giữa các token trong toàn bộ chuỗi đầu vào thông qua cơ chế attention, thay vì xử lý tuần tự như RNN hay LSTM. Điều này giúp cải thiện khả năng nắm bắt ngữ cảnh dài và tăng hiệu quả tính toán.

Quá trình phát triển LLM thường gồm hai giai đoạn chính:

- Pretraining: mô hình học các đặc trưng ngôn ngữ tổng quát từ khối lượng lớn dữ liệu, thường là dữ liệu không gán nhãn.
- Fine-tuning: mô hình được điều chỉnh trên các bộ dữ liệu hoặc nhiệm vụ cụ thể như hỏi đáp, tóm tắt, phân loại văn bản hoặc sinh nội dung.

1.3.2. Các mô hình tiêu biểu

1.3.2.1. BERT

BERT là mô hình dựa trên phần Encoder của Transformer, có khả năng tạo biểu diễn ngữ nghĩa hai chiều bằng cách khai thác đồng thời ngữ cảnh trước và sau mỗi token [4]. Mô hình được huấn luyện thông qua hai cơ chế chính:

- Masked Language Modeling (MLM): che giấu một số token trong câu và yêu cầu mô hình dự đoán lại các token bị che.
- Next Sentence Prediction (NSP): dự đoán mối quan hệ giữa hai câu liên tiếp.

Nhờ cách tiếp cận này, BERT đạt hiệu quả cao trong các nhiệm vụ hiểu văn bản như phân loại, trích xuất thông tin và hỏi đáp. Tuy nhiên, do được xây dựng theo hướng hiểu ngữ cảnh hai chiều, BERT không được tối ưu cho các bài toán sinh văn bản dài.

1.3.2.2. GPT

GPT là mô hình dựa trên phần Decoder của Transformer, sinh văn bản theo cơ chế tự hồi quy bằng cách dự đoán token tiếp theo dựa trên các token đã xuất hiện trước đó [18]. Các phiên bản GPT quy mô lớn cho thấy khả năng thực hiện nhiều nhiệm vụ xử lý ngôn ngữ tự nhiên thông qua cách thiết kế đầu vào phù hợp, đặc biệt trong bối cảnh few-shot learning [2].

Một số đặc điểm chính của GPT gồm:

- Được huấn luyện trên khối lượng lớn dữ liệu văn bản.
- Có khả năng sinh văn bản mạch lạc theo ngữ cảnh.
- Có thể thực hiện nhiều nhiệm vụ như hỏi đáp, tóm tắt, viết lại nội dung hoặc sinh văn bản thông qua prompt.

1.3.2.3. Gemini

Gemini là mô hình ngôn ngữ lớn đa phương thức do Google DeepMind phát triển, có khả năng xử lý nhiều dạng dữ liệu như văn bản, hình ảnh, âm thanh và thông tin phi cấu trúc trong cùng một kiến trúc [8]. So với các mô hình chỉ xử lý văn bản, Gemini phù hợp hơn với các bài toán yêu cầu phân tích và suy luận trên nhiều loại dữ liệu khác nhau.

Một số đặc điểm chính của Gemini gồm:

- Tích hợp nhiều dạng đầu vào trong cùng một mô hình thống nhất.

- Cải thiện khả năng suy luận khi bài toán liên quan đến nhiều loại thông tin khác nhau.
- Hỗ trợ các bài toán kết hợp ngôn ngữ tự nhiên với dữ liệu phi văn bản.

1.3.3. Hạn chế

Mặc dù LLM mang lại nhiều bước tiến quan trọng trong xử lý ngôn ngữ tự nhiên, các mô hình này vẫn tồn tại một số hạn chế khi áp dụng vào hệ thống thực tế [7]:

- Hiện tượng ảo giác (hallucination): mô hình có thể tạo ra thông tin nghe có vẻ hợp lý nhưng không chính xác hoặc không có căn cứ.
- Phụ thuộc vào dữ liệu huấn luyện: chất lượng, phạm vi và thời điểm thu thập dữ liệu ảnh hưởng trực tiếp đến độ chính xác của phản hồi.
- Chi phí tính toán cao: việc huấn luyện và triển khai LLM đòi hỏi tài nguyên phần cứng lớn, đặc biệt với các mô hình có quy mô tham số cao.
- Hạn chế khi xử lý ngữ cảnh dài: mô hình có thể gặp khó khăn khi đầu vào chứa nhiều tài liệu hoặc thông tin cần liên kết qua nhiều đoạn văn bản [9].
- Không tự cập nhật tri thức: LLM không tự động nắm bắt các thông tin mới phát sinh sau thời điểm huấn luyện nếu không có cơ chế bổ sung dữ liệu bên ngoài.

Do đó, trong các hệ thống ứng dụng thực tế, LLM thường được kết hợp với Retrieval-Augmented Generation nhằm bổ sung khả năng truy xuất thông tin từ nguồn dữ liệu bên ngoài, giảm phụ thuộc vào tri thức nội tại của mô hình và cải thiện độ tin cậy của phản hồi [7].

1.4. Retrieval-Augmented Generation (RAG)

1.4.1. Khái niệm


Retrieval-Augmented Generation (RAG) là phương pháp kết hợp mô hình ngôn ngữ lớn với cơ chế truy xuất thông tin từ nguồn dữ liệu bên ngoài [11]. Thay vì phụ thuộc hoàn toàn vào tri thức được học trong quá trình huấn luyện, mô hình có thể tham chiếu thêm các tài liệu liên quan tại thời điểm xử lý truy vấn để hỗ trợ tạo câu trả lời.

Về bản chất, RAG tách biệt tương đối giữa khả năng sinh ngôn ngữ của LLM và nguồn tri thức được sử dụng. Tri thức có thể được lưu trữ, cập nhật và truy xuất từ bên ngoài mô hình, qua đó giúp hệ thống linh hoạt hơn trong các bài toán yêu cầu thông tin mới, thông tin chuyên ngành hoặc dữ liệu thay đổi theo thời gian [7].

1.4.2. Kiến trúc và quy trình hoạt động

Kiến trúc của RAG được xây dựng dựa trên sự kết hợp giữa cơ chế truy xuất thông tin và mô hình sinh ngôn ngữ. Trong đó, tri thức không chỉ nằm trong tham số của mô hình mà còn được lưu trữ ở kho dữ liệu bên ngoài và được truy xuất khi có truy vấn từ người dùng.

Về tổng thể, một hệ thống RAG thường bao gồm ba thành phần chính: kho tri thức (Knowledge Base), bộ truy xuất thông tin (Retriever) và mô hình sinh ngôn ngữ (Generator) [7], [11].



Hình 1.1. Kiến trúc tổng quát của hệ thống RAG

Quy trình hoạt động của hệ thống RAG có thể được mô tả qua bốn bước chính:

– **Tiếp nhận truy vấn**

- + Người dùng gửi câu hỏi hoặc yêu cầu đến hệ thống.

- + Truy vấn đầu vào được chuẩn hóa và chuyển sang dạng phù hợp để phục vụ quá trình tìm kiếm.
- **Truy xuất tài liệu liên quan**
 - + Retriever thực hiện tìm kiếm trong kho tri thức dựa trên nội dung truy vấn.
 - + Hệ thống lựa chọn các tài liệu hoặc đoạn văn bản có mức độ liên quan cao nhất.
 - + Kết quả truy xuất thường là một tập các đoạn thông tin ngắn phục vụ cho bước sinh câu trả lời.
- **Xây dựng ngữ cảnh**
 - + Các tài liệu được truy xuất được ghép với truy vấn ban đầu.
 - + Tập thông tin này tạo thành ngữ cảnh mở rộng (augmented context) cho mô hình ngôn ngữ.
 - + Ngữ cảnh mở rộng giúp mô hình có thêm dữ liệu tham chiếu khi sinh phản hồi.
- **Sinh câu trả lời**
 - + Generator hoặc LLM sử dụng truy vấn cùng với các tài liệu liên quan để tạo ra câu trả lời.
 - + Câu trả lời được xây dựng dựa trên cả kiến thức nội tại của mô hình và thông tin được truy xuất từ kho tri thức.
 - + Nhờ đó, đầu ra thường có độ chính xác và tính cập nhật cao hơn so với cách tiếp cận chỉ sử dụng mô hình ngôn ngữ độc lập.

Nhờ cơ chế này, RAG giúp mô hình khai thác được thông tin từ nguồn dữ liệu bên ngoài, qua đó giảm phụ thuộc vào tri thức nội tại của LLM, hỗ trợ cập nhật thông tin linh hoạt hơn và cải thiện độ tin cậy của phản hồi [7].

1.4.3. Vai trò của RAG trong hệ thống ứng dụng LLM

Trong các hệ thống ứng dụng thực tế, RAG đóng vai trò quan trọng trong việc mở rộng khả năng của LLM vượt ra ngoài giới hạn tri thức nội tại của mô hình [7], [11]. Cụ thể, RAG mang lại một số lợi ích chính:

- Cho phép bổ sung và cập nhật tri thức thông qua kho dữ liệu bên ngoài mà không cần huấn luyện lại toàn bộ mô hình.
- Tăng khả năng kiểm soát và truy vết nguồn gốc thông tin được sử dụng trong quá trình sinh phản hồi.
- Hỗ trợ tốt hơn cho các bài toán theo miền chuyên biệt nhờ khả năng tích hợp dữ liệu riêng của từng hệ thống.

Trong bài toán du lịch, vai trò này đặc biệt quan trọng vì thông tin về điểm đến, dịch vụ, chi phí, thời gian mở cửa hoặc điều kiện tham quan có thể thay đổi theo thời gian. Khi kho tri thức được cập nhật phù hợp, cơ chế truy xuất giúp hệ thống đối chiếu yêu cầu của người dùng với các nguồn dữ liệu liên quan trước khi sinh phản hồi. Nhờ đó, kết quả gợi ý có khả năng phù hợp hơn với ngữ cảnh thực tế tại thời điểm truy vấn.

1.4.4. Ưu điểm và hạn chế

Trong quá trình triển khai thực tế, RAG thể hiện cả ưu điểm lẫn hạn chế khi xét trên khía cạnh chất lượng phản hồi, khả năng cập nhật tri thức và mức độ phức tạp của hệ thống. Bảng 1.1 tổng hợp các đặc điểm chính của RAG [7], [11].

Bảng 1.1. Ưu điểm và hạn chế của RAG

Ưu điểm	Hạn chế
Mở rộng khả năng sử dụng tri thức ngoài mô hình, giảm phụ thuộc vào tham số đã huấn luyện	Phụ thuộc đáng kể vào chất lượng, độ chính xác và mức độ cập nhật của nguồn dữ liệu truy xuất
Cho phép cập nhật thông tin thông qua kho dữ liệu bên ngoài mà không cần huấn luyện lại mô hình	Hiệu quả đầu ra bị ảnh hưởng nếu bộ truy xuất chọn sai, thiếu hoặc nhiều thông tin liên quan
Hỗ trợ tốt các bài toán theo miền nhờ khả năng tích hợp dữ liệu chuyên biệt	Làm tăng độ phức tạp trong thiết kế, triển khai và vận hành hệ thống so với LLM thuần túy

Giúp phản hồi bám sát hơn vào yêu cầu người dùng và tài liệu được truy xuất	Tăng thời gian xử lý do phát sinh thêm bước truy xuất trước khi sinh kết quả
Tăng khả năng kiểm soát và truy vết nguồn thông tin đầu ra	Cần thiết kế tốt cơ chế thu thập, tổ chức, chia đoạn và biểu diễn dữ liệu để đạt hiệu quả cao

1.5. Hybrid Search và Reranking

Trong hệ thống RAG, chất lượng ngữ cảnh truy xuất ảnh hưởng trực tiếp đến kết quả sinh câu trả lời. Khi tài liệu đầu vào thiếu liên quan, không đầy đủ hoặc chứa nhiễu, mô hình ngôn ngữ có thể tạo ra phản hồi sai lệch. Vì vậy, bên cạnh việc xây dựng kho tri thức, cải thiện giai đoạn truy xuất là một yêu cầu quan trọng. Hai kỹ thuật thường được áp dụng để nâng cao chất lượng tài liệu đầu vào là Hybrid Search và Reranking.

1.5.1. Hybrid Search

Hybrid Search kết hợp đồng thời nhiều phương pháp truy xuất nhằm tận dụng ưu điểm bổ trợ của từng phương pháp [12]. Trong các hệ thống RAG, kỹ thuật này thường kết hợp hai hướng truy xuất chính:

- Dense Retrieval: sử dụng mô hình embedding để ánh xạ truy vấn và tài liệu vào cùng một không gian vector [10]. Mức độ liên quan được đo bằng độ tương đồng giữa các vector, giúp hệ thống nắm bắt quan hệ ngữ nghĩa ngay cả khi truy vấn và tài liệu không chia sẻ nhiều từ khóa giống nhau.
- Sparse Retrieval: điển hình là BM25 [17], đánh giá mức độ liên quan dựa trên tần suất và mức độ phân biệt của từ khóa trong tài liệu [16]. Phương pháp này phù hợp với các truy vấn chứa thực thể, tên địa danh hoặc thuật ngữ cụ thể, nhưng có thể hạn chế khi người dùng diễn đạt lại ý bằng các từ ngữ khác.

Việc kết hợp cả thông tin ngữ nghĩa và từ khóa giúp hệ thống mở rộng khả năng tìm kiếm tài liệu liên quan, đồng thời giảm nguy cơ bỏ sót nội dung quan trọng trong kho tri thức.

1.5.2. Reranking

Reranking là bước đánh giá lại và sắp xếp lại thứ tự các tài liệu sau giai đoạn truy xuất ban đầu, nhằm ưu tiên những tài liệu có mức độ liên quan cao hơn với truy vấn của người dùng [14]. Khác với truy xuất ban đầu thường ưu tiên tốc độ và phạm vi bao phủ, Reranking sử dụng mô hình học sâu để xem xét đồng thời nội dung truy vấn và văn bản, từ đó xác định mức độ phù hợp chi tiết hơn.

Trong kiến trúc RAG, Reranking đóng vai trò tinh chỉnh tập tài liệu trước khi xây dựng ngữ cảnh đầu vào cho LLM. Bước này giúp giảm nhiễu thông tin, ưu tiên các đoạn nội dung quan trọng và cải thiện khả năng sinh câu trả lời chính xác.

1.6. Các nghiên cứu và hệ thống liên quan

Các công trình và hệ thống liên quan có thể chia thành hai nhóm chính: nền tảng du lịch thương mại và nghiên cứu ứng dụng LLM trong lĩnh vực gợi ý, lập kế hoạch du lịch.

1.6.1. Các nền tảng du lịch truyền thống

Các nền tảng du lịch trực tuyến hiện nay hỗ trợ người dùng trong quá trình tìm kiếm thông tin, tham khảo đánh giá, lựa chọn điểm đến và đặt dịch vụ. Một số hệ thống tiêu biểu có thể kể đến như TripAdvisor, Google Travel và Booking.com. Bảng 1.2 trình bày khái quát đặc điểm và hạn chế của các nền tảng này.

Bảng 1.2. Một số nền tảng du lịch thương mại tiêu biểu

Hệ thống	Đặc điểm	Hạn chế
TripAdvisor	Cung cấp thông tin về điểm đến, khách sạn, nhà hàng, hoạt động du lịch và đánh giá từ cộng đồng người dùng	Người dùng vẫn cần tự chọn lọc thông tin và xây dựng lịch trình phù hợp với nhu cầu cá nhân
Google Travel	Hỗ trợ tìm kiếm thông tin du lịch, chuyến bay, khách sạn và gợi ý	Khả năng lập lịch trình chi tiết và cá nhân hóa sâu theo nhiều ràng buộc cụ thể còn hạn chế

	điểm đến dựa trên hệ sinh thái dữ liệu của Google	
Booking.com	Tập trung vào tìm kiếm, so sánh và đặt dịch vụ lưu trú, đồng thời cung cấp đánh giá từ khách hàng	Chủ yếu phục vụ bài toán lưu trú, chưa bao quát đầy đủ quá trình gợi ý điểm đến và xây dựng lịch trình tổng thể

Nhìn chung, các nền tảng thương mại hiện nay sở hữu nguồn dữ liệu phong phú và khả năng tìm kiếm thuận tiện. Tuy nhiên, phần lớn vẫn yêu cầu người dùng tự tổng hợp, so sánh và điều chỉnh thông tin từ nhiều nguồn khác nhau trước khi đưa ra quyết định cuối cùng. Đây là khoảng trống để các hệ thống gợi ý cá nhân hóa dựa trên LLM và RAG có thể hỗ trợ tốt hơn trong việc hiểu nhu cầu, khai thác tri thức đa nguồn và tạo lịch trình phù hợp với từng người dùng.

1.6.2. Các hệ thống tích hợp LLM

Sự xuất hiện của các mô hình ngôn ngữ lớn đã mở ra hướng tiếp cận mới cho bài toán gợi ý và lập kế hoạch. Thay vì chỉ trả về danh sách kết quả tìm kiếm, hệ thống có thể tương tác bằng ngôn ngữ tự nhiên, phân tích nhu cầu của người dùng và tạo ra các đề xuất có tính tổng hợp hơn.

Bảng 1.3. Một số nghiên cứu ứng dụng LLM trong gợi ý và lập kế hoạch

Nghiên cứu	Hướng tiếp cận	Hạn chế
Chat-Rec [6]	Sử dụng LLM để tăng khả năng tương tác và giải thích trong hệ thống gợi ý	Chưa tập trung vào bài toán du lịch và lập lịch trình theo nhiều ràng buộc thực tế
TravelPlanner [19]	Xây dựng bài toán lập kế hoạch du lịch bằng language agents, nhấn mạnh đến các ràng buộc	Chưa tập trung vào bối cảnh du lịch Việt Nam và chưa giải quyết sâu bài toán cá nhân hóa theo dữ liệu người dùng địa phương

	thực tế trong quá trình lên lịch trình	
--	--	--

Các nghiên cứu trên cho thấy tiềm năng của LLM trong việc nâng cao trải nghiệm người dùng thông qua giao tiếp tự nhiên, khả năng tổng hợp thông tin và hỗ trợ lập kế hoạch. Tuy nhiên, việc đảm bảo tính chính xác, khả năng cập nhật tri thức và mức độ cá nhân hóa theo bối cảnh cụ thể vẫn là những thách thức quan trọng. Bên cạnh đó, các nghiên cứu tổng quan về RAG cho thấy việc kết hợp LLM với cơ chế truy xuất tri thức bên ngoài là một hướng phù hợp để giảm phụ thuộc vào tri thức nội tại của mô hình và cải thiện độ tin cậy của phản hồi [7]. Đây là cơ sở để luận văn đề xuất hướng kết hợp LLM với RAG cho bài toán gợi ý du lịch cá nhân hóa tại Việt Nam.

1.6.3. Khoảng trống nghiên cứu

Qua khảo sát các nền tảng thương mại và công trình nghiên cứu liên quan, có thể nhận thấy một số khoảng trống chính:

- Phần lớn hệ thống hiện nay mới tập trung vào từng khía cạnh riêng lẻ như tìm kiếm thông tin, gợi ý địa điểm hoặc lập lịch trình, trong khi việc kết hợp giữa truy xuất tri thức, sinh phản hồi và cá nhân hóa theo nhu cầu người dùng vẫn còn hạn chế.
- Nhiều nghiên cứu và bộ dữ liệu được xây dựng trong bối cảnh quốc tế hoặc tiếng Anh, nên khi áp dụng vào du lịch Việt Nam có thể gặp khó khăn do đặc thù về địa danh, ngôn ngữ, văn hóa, chi phí và hành vi du lịch địa phương.
- Trong các hướng triển khai RAG cơ bản, chất lượng kết quả vẫn phụ thuộc lớn vào giai đoạn truy xuất. Nếu chỉ dựa vào một phương pháp tìm kiếm hoặc chưa có bước reranking phù hợp, hệ thống có thể bỏ sót thông tin quan trọng hoặc đưa vào ngữ cảnh các tài liệu chưa thật sự liên quan.

Những khoảng trống trên là cơ sở để luận văn đề xuất hướng tiếp cận kết hợp LLM, RAG, Hybrid Search và Reranking cho bài toán gợi ý du lịch cá nhân hóa tại Việt Nam.

1.7. Kết luận chương 1

Chương 1 đã trình bày nền tảng lý thuyết của luận văn, bao gồm:

- Hệ thống gợi ý và bài toán cá nhân hóa trong lĩnh vực du lịch.
- Mô hình ngôn ngữ lớn (LLM): kiến trúc Transformer, các mô hình tiêu biểu và hạn chế.
- Kỹ thuật Retrieval-Augmented Generation (RAG): khái niệm, kiến trúc và vai trò.
- Hybrid Search và Reranking: các phương pháp nâng cao chất lượng truy xuất.
- Khảo sát các công trình liên quan và xác định khoảng trống nghiên cứu.

Trên cơ sở đó, việc kết hợp LLM với RAG, Hybrid Search và Reranking là hướng tiếp cận phù hợp để giải quyết bài toán gợi ý du lịch cá nhân hóa tại Việt Nam. Chương tiếp theo sẽ tập trung vào phân tích bài toán và đề xuất kiến trúc hệ thống.

Chương 2: PHÂN TÍCH BÀI TOÁN VÀ THIẾT KẾ NỀN TẢNG

2.1. Phân tích bài toán

2.1.1. Mô tả bài toán và người dùng

Mục tiêu của bài toán là phát triển một hệ thống có khả năng hỗ trợ người dùng xây dựng lịch trình du lịch mang tính cá nhân hóa tại Việt Nam. Thay vì phải tự tìm kiếm và tổng hợp thông tin từ nhiều nguồn khác nhau, người dùng chỉ cần mô tả nhu cầu của mình bằng ngôn ngữ tự nhiên. Hệ thống sẽ tiếp nhận, phân tích nội dung yêu cầu, sau đó khai thác dữ liệu liên quan để đề xuất một lịch trình phù hợp.

Chẳng hạn, người dùng có thể đưa ra yêu cầu như: “Tôi muốn đi Đà Nẵng 3 ngày 2 đêm vào tháng 8, ngân sách khoảng 8 triệu đồng, ưu tiên nghỉ dưỡng và ẩm thực địa phương.” Từ thông tin này, hệ thống cần nhận diện các yếu tố chính như địa điểm, thời gian, ngân sách, sở thích và mục tiêu chuyến đi, rồi sử dụng dữ liệu trong kho tri thức để xây dựng kế hoạch tương ứng.

Thông tin đầu vào của hệ thống bao gồm:

- Các chi tiết về chuyến đi như điểm đến, thời gian bắt đầu và số ngày lưu trú.
- Mức chi tiêu dự kiến của người dùng.
- Sở thích cá nhân, nhu cầu trải nghiệm và các điều kiện ràng buộc.
- Dữ liệu hội thoại trước đó hoặc hồ sơ người dùng (nếu có).

Kết quả đầu ra là một lịch trình du lịch được sắp xếp theo từng ngày, bao gồm:

- Danh sách các địa điểm và hoạt động đề xuất, có thể kèm theo tọa độ địa lý.
- Thời gian dự kiến cho từng hoạt động hoặc điểm tham quan.
- Chi phí ước lượng cho từng phần hoặc toàn bộ chuyến đi.
- Mô tả chi tiết giúp người dùng dễ hiểu và có thể điều chỉnh khi cần.

Lịch trình được tạo ra cần đảm bảo sự hợp lý về mặt thời gian, khoảng cách di chuyển giữa các địa điểm cũng như phù hợp với ngân sách đã đề ra. Bên cạnh đó, các thông tin quan trọng nên được lấy từ hoặc kiểm chứng với kho tri thức của hệ thống nhằm đảm bảo độ chính xác và độ tin cậy.

Phạm vi nghiên cứu tập trung vào du lịch nội địa tại Việt Nam, chủ yếu phục vụ việc tư vấn, gợi ý điểm đến và xây dựng lịch trình cá nhân hóa. Hệ thống không hỗ

trợ các chức năng như đặt vé, đặt phòng hay thanh toán. Dữ liệu sử dụng được thu thập từ các nguồn mở và được xử lý, chuẩn hóa trong quá trình xây dựng kho tri thức.

2.1.2. Yêu cầu chức năng

Từ bài toán đã xác định, hệ thống cần đáp ứng các yêu cầu chức năng chính được trình bày trong Bảng 2.1.

Bảng 2.1. Yêu cầu chức năng của hệ thống

STT	Yêu cầu chức năng	Mô tả
1	Tương tác hội thoại	Cho phép người dùng trao đổi với hệ thống bằng ngôn ngữ tự nhiên tiếng Việt để yêu cầu gợi ý lịch trình, hỏi thông tin du lịch hoặc điều chỉnh yêu cầu qua nhiều lượt hội thoại.
2	Phân tích yêu cầu người dùng	Nhận diện ý định và trích xuất các thông tin quan trọng từ truy vấn như điểm đến, thời gian, số ngày, ngân sách, sở thích, nhóm đi và các ràng buộc cá nhân.
3	Truy xuất tri thức du lịch	Tìm kiếm và truy xuất thông tin liên quan từ kho tri thức du lịch Việt Nam để hỗ trợ quá trình tạo gợi ý và lịch trình.
4	Tích hợp thông tin thời tiết	Truy xuất thông tin thời tiết tại điểm đến trong khoảng thời gian dự kiến và đưa vào ngữ cảnh đầu vào cho LLM, giúp hệ thống điều chỉnh gợi ý hoạt động và lịch trình phù hợp hơn.
5	Gợi ý địa điểm	Đề xuất điểm tham quan, nhà hàng, hoạt động hoặc khu vực lưu trú phù hợp với nhu cầu người dùng khi chưa cần xây dựng lịch trình hoàn chỉnh.

6	Sinh lịch trình tự động	Tạo lịch trình du lịch theo từng ngày, bao gồm địa điểm, hoạt động, thời gian dự kiến, chi phí ước lượng và thông tin mô tả cần thiết.
7	Cá nhân hóa đề xuất	Điều chỉnh kết quả gợi ý dựa trên hồ sơ sở thích, lịch sử hội thoại, ngân sách, nhóm đi, thông tin thời tiết và phản hồi của người dùng.
8	Quản lý lịch trình	Cho phép người dùng lưu, chỉnh sửa, sắp xếp lại hoạt động, thay đổi thứ tự điểm đến hoặc điều chỉnh lịch trình theo nhu cầu.
9	Hiển thị bản đồ	Trực quan hóa các địa điểm trong lịch trình trên bản đồ, hỗ trợ người dùng quan sát vị trí và khoảng cách giữa các điểm đến.
10	Quản lý tài khoản và hồ sơ	Hỗ trợ đăng ký, đăng nhập, quản lý thông tin cá nhân và cài đặt sở thích du lịch phục vụ cá nhân hóa.
11	Chia sẻ lịch trình	Cho phép tạo liên kết chia sẻ lịch trình cho người khác xem mà không cần chỉnh sửa trực tiếp dữ liệu gốc.

2.1.3. Yêu cầu phi chức năng

Bên cạnh các chức năng chính, hệ thống cần đáp ứng một số yêu cầu phi chức năng nhằm đảm bảo khả năng vận hành ổn định, an toàn và phù hợp với bài toán gợi ý du lịch cá nhân hóa. Các yêu cầu này được trình bày trong Bảng 2.2.


Bảng 2.2. Yêu cầu phi chức năng của hệ thống

STT	Yêu cầu	Mô tả
1	Hiệu năng xử lý	Hệ thống cần phản hồi trong thời gian hợp lý đối với các truy vấn gợi ý, truy xuất tri thức và sinh lịch trình, đảm bảo trải nghiệm hội thoại không bị gián đoạn.
2	Khả năng mở rộng	Kiến trúc hệ thống cần hỗ trợ mở rộng khi số lượng người dùng, dữ liệu du lịch và khối lượng truy vấn tăng lên, đặc biệt ở các thành phần kho tri thức, truy xuất và xử lý LLM.
3	Độ tin cậy	Kết quả sinh ra cần bám sát dữ liệu được truy xuất từ kho tri thức, hạn chế thông tin sai lệch và đảm bảo tính nhất quán trong các phản hồi quan trọng.
4	Tính sẵn sàng	Hệ thống cần duy trì khả năng hoạt động ổn định, hạn chế thời gian gián đoạn dịch vụ trong quá trình người dùng tương tác và xây dựng lịch trình.
5	Bảo mật dữ liệu	Thông tin tài khoản, hồ sơ sở thích, lịch sử hội thoại và lịch trình cá nhân của người dùng cần được lưu trữ, truyền tải và xử lý an toàn, tránh truy cập trái phép.
6	Khả năng tương thích	Giao diện hệ thống cần hiển thị phù hợp trên nhiều thiết bị, đặc biệt là trình duyệt web trên máy tính và thiết bị di động.
7	Khả năng bảo trì	Hệ thống cần được thiết kế theo hướng module hóa, tách biệt các thành phần như giao diện, API, truy xuất dữ liệu, xử lý LLM và quản lý người dùng để thuận tiện cho nâng cấp và mở rộng.
8	Tính nhất quán dữ liệu	Dữ liệu giữa cơ sở dữ liệu quan hệ, kho vector, kho tri thức và lịch sử hội thoại cần được đồng bộ hợp lý nhằm tránh sai lệch trong quá trình truy xuất và cá nhân hóa.

2.2. Kiến trúc hệ thống

2.2.1. Kiến trúc tổng thể

Hệ thống được thiết kế theo kiến trúc ba tầng, trong đó tầng xử lý nghiệp vụ được triển khai theo hướng module hóa nhằm tăng tính linh hoạt và khả năng mở rộng. Ba tầng chính bao gồm: tầng giao diện, tầng xử lý nghiệp vụ và tầng dữ liệu.



Hình 2.1. Kiến trúc tổng quát của hệ thống

Tầng giao diện được xây dựng trên nền tảng Next.js, đảm nhiệm việc hiển thị giao diện hội thoại, trực quan hóa lộ trình trên bản đồ Leaflet và cung cấp chức năng quản lý lộ trình. Xác thực phía client được xử lý thông qua NextAuth. Tầng này giao tiếp với tầng xử lý nghiệp vụ thông qua REST API và cơ chế SSE Streaming nhằm hỗ trợ cập nhật kết quả theo thời gian thực.

Tầng xử lý nghiệp vụ được xây dựng trên framework FastAPI, bao gồm các module được phân chia theo chức năng và được điều phối bởi một pipeline xử lý hội thoại (Chat Pipeline). Đây là thành phần trung tâm của hệ thống, chịu trách nhiệm tiếp nhận yêu cầu từ người dùng, điều phối luồng xử lý giữa các module và tổng hợp kết quả đầu ra.

Các module trong tầng này được tổ chức thành bốn nhóm chính:

– **Nhóm xử lý ngôn ngữ**

- + NLU Service: phân tích ý định và trích xuất thực thể từ câu tiếng Việt.
- + Memory Service: quản lý ngữ cảnh hội thoại.
- + LLM Service: tương tác với mô hình Gemini.
- + Context Compressor: nén ngữ cảnh trích xuất.
- + NLI Service: kiểm tra tính trung thực của kết quả.

– **Nhóm gợi ý và tối ưu lộ trình**

- + RAG Pipeline: thực hiện truy xuất, xếp hạng lại tài liệu, xây dựng ngữ cảnh và sinh phản hồi.
- + Recommendation Service: gợi ý địa điểm theo sở thích.
- + Route Optimizer: hậu xử lý lộ trình.
- + Location Service: trích xuất vị trí, tính khoảng cách OSRM.

– **Nhóm phân tích và cải tiến**

- + Preference Learning: học sở thích từ phản hồi người dùng.
- + RAG Evaluator: đánh giá chất lượng kết quả.
- + Metrics Service: thu thập độ đo hệ thống.
- + Debug Logger: ghi log chi tiết toàn pipeline phục vụ giám sát và tối ưu.

– **Nhóm hỗ trợ hệ thống:**

- + Auth Service: xác thực và phân quyền người dùng.
- + Weather Service: truy vấn dữ liệu thời tiết.

Ngoài ra, hệ thống có tích hợp một số dịch vụ bên ngoài nhằm hỗ trợ quá trình xử lý và nâng cao chất lượng kết quả, bao gồm:


- Gemini API: sinh nội dung.
- OSRM API: tính khoảng cách thực tế.
- Weather API: dự báo thời tiết.

Tầng dữ liệu sử dụng PostgreSQL tích hợp pgvector, lưu trữ cả dữ liệu quan hệ như người dùng, lịch trình, điểm đến và dữ liệu vector phục vụ truy xuất ngữ nghĩa.

Kho tri thức được xây dựng từ các nguồn như OpenStreetMap, Wikipedia song ngữ Việt – Anh và dữ liệu đã được tổng hợp, chuẩn hóa trong quá trình xây dựng hệ thống. Sau khi xử lý, các đoạn văn bản được chuyển đổi thành embedding và lưu trữ trong cơ sở dữ liệu.

2.2.2. *Luồng xử lý*

Hệ thống xử lý yêu cầu của người dùng thông qua một chuỗi các bước liên tiếp, bắt đầu từ việc tiếp nhận yêu cầu, phân tích ngữ cảnh, truy xuất tri thức và kết thúc bằng việc sinh lộ trình hoàn chỉnh. Luồng xử lý tổng quát của hệ thống được mô tả trong hình:



Hình 2.2. Luồng xử lý chính của hệ thống

Bước 1: Quản lý ngữ cảnh hội thoại

Khi người dùng gửi yêu cầu, hệ thống trước tiên xử lý ngữ cảnh hội thoại hiện tại. Các thông tin từ những lượt trao đổi trước được tổng hợp nhằm duy trì tính liên tục của cuộc hội thoại và hỗ trợ việc hiểu đúng nội dung yêu cầu.

Trong bước này, hệ thống thực hiện:

- Tổng hợp các thông tin liên quan từ lịch sử hội thoại.
- Phân giải các tham chiếu ngữ cảnh như địa điểm hoặc đối tượng đã được đề cập trước đó.
- Xây dựng ngữ cảnh đầu vào cho các bước xử lý tiếp theo.

Bước 2: Phân tích yêu cầu người dùng

Sau khi xác định được ngữ cảnh, hệ thống tiến hành phân tích nội dung yêu cầu nhằm nhận diện ý định và trích xuất các thông tin cần thiết. Đồng thời, hệ thống thực hiện truy vấn tìm kiếm sơ bộ trên kho tri thức để tối ưu hóa thời gian phản hồi.

Các thông tin được xác định bao gồm:

- Điểm đến mong muốn
- Thời gian hoặc số ngày du lịch
- Ngân sách dự kiến
- Sở thích và nhu cầu trải nghiệm
- Nhóm người tham gia

Bước 3: Kiểm tra tính đầy đủ của thông tin

Hệ thống đánh giá mức độ đầy đủ của dữ liệu đã thu thập được. Nếu còn thiếu các thông tin quan trọng ảnh hưởng đến việc xây dựng lộ trình, hệ thống sẽ chủ động yêu cầu người dùng bổ sung trước khi tiếp tục xử lý.

Bên cạnh đó, hệ thống cũng nhận diện các câu trả lời tiếp nối từ người dùng để tự động cập nhật và điều chỉnh ý định xử lý cho phù hợp. Việc kiểm tra này giúp hạn chế các trường hợp tạo ra kết quả không phù hợp do thiếu dữ liệu đầu vào.

Bước 4: Định tuyến yêu cầu

Tùy thuộc vào loại yêu cầu được nhận diện, hệ thống lựa chọn quy trình xử lý phù hợp:

- Yêu cầu lập kế hoạch hoặc gợi ý du lịch sẽ kích hoạt toàn bộ quy trình truy xuất và sinh nội dung.
- Yêu cầu tra cứu thông tin sử dụng quy trình truy xuất rút gọn.
- Các câu hỏi thoại thông thường được xử lý theo cơ chế hội thoại cơ bản.
- Cơ chế dự phòng (fallback) tự động chuyển đổi phương thức xử lý khi có lỗi từ dịch vụ bên ngoài.

Bước 5: Truy xuất tri thức và sinh kết quả

Đây là giai đoạn trung tâm của hệ thống. Trên cơ sở yêu cầu đã được chuẩn hóa, hệ thống thực hiện truy xuất các thông tin liên quan từ kho tri thức và các nguồn dữ liệu hỗ trợ.

Quá trình này bao gồm:

- Tìm kiếm các tài liệu liên quan trong kho tri thức.
- Kết hợp dữ liệu từ cơ sở dữ liệu hệ thống.
- Lựa chọn các thông tin phù hợp với ngữ cảnh người dùng.
- Xây dựng ngữ cảnh đầu vào cho mô hình ngôn ngữ.
- Sinh lộ trình hoặc câu trả lời tương ứng.

Bước 6: Hậu xử lý kết quả

Kết quả sinh ra từ mô hình tiếp tục được kiểm tra và hiệu chỉnh trước khi gửi tới người dùng. Một số tác vụ trong bước này được thực thi song song để rút ngắn thời gian xử lý.

Các bước xử lý bao gồm:

- Chuẩn hóa thông tin địa điểm và tọa độ.
- Tính toán và tối ưu hóa khoảng cách giữa các điểm trong lộ trình.
- Đối chiếu chi phí và kiểm tra mức độ tuân thủ ngân sách của người dùng để đưa ra lời khuyên phù hợp.
- Kiểm tra tính trung thực của thông tin nhằm hạn chế nội dung không có cơ sở từ kho tri thức (hallucination).

Bước 7: Trả kết quả và cập nhật hồ sơ người dùng

Sau khi hoàn tất xử lý, hệ thống thực hiện:

- Tự động đánh giá chất lượng kết quả phục vụ giám sát.
- Truyền lộ trình hoặc câu trả lời về giao diện theo thời gian thực (SSE Streaming).
- Lưu kết quả vào bộ nhớ đệm (Cache) nhằm tối ưu hiệu suất cho các truy vấn tương tự.
- Ghi nhận sở thích và hành vi tương tác để cập nhật hồ sơ cá nhân, phục vụ cá nhân hóa ở các lần sử dụng tiếp theo.

2.2.3. Công nghệ sử dụng

Trong quá trình xây dựng hệ thống, các công nghệ được lựa chọn nhằm đáp ứng yêu cầu về hiệu năng, khả năng mở rộng, mức độ phù hợp với bài toán và khả năng tích hợp với các thành phần LLM/RAG. Bảng 2.3 trình bày tổng hợp các công nghệ chính được sử dụng.

Bảng 2.3. Công nghệ sử dụng trong hệ thống

Vai trò	Công nghệ	Ghi chú
Ứng dụng web	Next.js 16 + React 19	Xây dựng giao diện người dùng
API Server	FastAPI	Xử lý nghiệp vụ và cung cấp API
Cơ sở dữ liệu	PostgreSQL 16 + pgvector	Lưu trữ dữ liệu quan hệ và dữ liệu vector
Mô hình ngôn ngữ lớn	Google Gemini 2.5 Flash	Phân tích yêu cầu và sinh nội dung
Framework RAG	LangChain	Điều phối quy trình truy xuất và sinh phản hồi
Embedding	Gemini Embedding	Sinh vector biểu diễn ngữ nghĩa cho tài liệu và truy vấn

Xếp hạng lại tài liệu	Cross-Encoder	Reranking kết quả truy xuất
Đối chiếu kết quả sinh	Natural Language Inference	Kiểm tra mức độ nhất quán giữa nội dung sinh ra và dữ liệu tham chiếu
Tính khoảng cách	OSRM	Tính toán khoảng cách và thời gian di chuyển thực tế
Dữ liệu thời tiết	Open-Meteo	Cung cấp thông tin thời tiết cho điểm đến
Dữ liệu địa lý	Overpass API (OpenStreetMap)	Thu thập dữ liệu địa lý và thông tin điểm đến

Lý do lựa chọn công nghệ:

- PostgreSQL 16 + pgvector: cho phép quản lý đồng thời dữ liệu quan hệ và dữ liệu vector trên cùng một nền tảng, giúp đơn giản hóa kiến trúc lưu trữ và thuận lợi cho việc triển khai hệ thống RAG.
- Google Gemini 2.5 Flash: được lựa chọn làm mô hình ngôn ngữ trung tâm nhờ khả năng xử lý tiếng Việt, hỗ trợ phân tích yêu cầu người dùng và sinh nội dung với chi phí phù hợp cho hệ thống thực nghiệm.
- LangChain: được sử dụng để điều phối các thành phần trong pipeline RAG, hỗ trợ kết nối giữa mô hình ngôn ngữ, kho tri thức, bộ truy xuất và các nguồn dữ liệu bên ngoài.
- Gemini Embedding: đảm nhiệm việc chuyển đổi dữ liệu văn bản thành vector biểu diễn ngữ nghĩa, phục vụ quá trình tìm kiếm và truy xuất thông tin liên quan.
- Cross-Encoder: được sử dụng ở bước xếp hạng lại kết quả truy xuất nhằm nâng cao độ chính xác của các tài liệu được đưa vào ngữ cảnh cho mô hình ngôn ngữ.

- Natural Language Inference (NLI): hỗ trợ đối chiếu mức độ nhất quán giữa nội dung sinh ra và dữ liệu tham chiếu, góp phần hạn chế các phản hồi không phù hợp hoặc thiếu căn cứ.
- OSRM, Open-Meteo và Overpass API: được tích hợp nhằm bổ sung dữ liệu về khoảng cách di chuyển, thời tiết và thông tin địa lý, qua đó nâng cao tính khả thi của lịch trình được đề xuất.


2.3. Thiết kế dữ liệu và kho tri thức

2.3.1. Cơ sở dữ liệu quan hệ

Hệ thống sử dụng PostgreSQL làm cơ sở dữ liệu quan hệ chính. Lược đồ dữ liệu được thiết kế theo bốn nhóm chức năng, nhằm đảm bảo tính toàn vẹn dữ liệu và thuận lợi cho việc mở rộng hệ thống.



Hình 2.3a. Sơ đồ ERD nhóm bảng người dùng, hội thoại và lộ trình



Hình 2.3b. Sơ đồ ERD nhóm bảng dữ liệu du lịch

Dựa trên chức năng nghiệp vụ, các bảng dữ liệu được chia thành bốn nhóm chính:

Nhóm dữ liệu người dùng: quản lý thông tin tài khoản và hồ sơ cá nhân phục vụ quá trình cá nhân hóa.

- users: lưu trữ thông tin tài khoản người dùng như tên, email, mật khẩu đã mã hóa và trạng thái hoạt động.
- user_preferences: lưu trữ hồ sơ sở thích du lịch, bao gồm phong cách du lịch, sở thích trải nghiệm, ưu tiên ẩm thực và các thông tin được hệ thống học hỏi trong quá trình sử dụng.

Hai bảng được liên kết theo quan hệ một-một (1:1), trong đó mỗi người dùng tương ứng với một hồ sơ sở thích.

Nhóm dữ liệu hội thoại: hỗ trợ duy trì ngữ cảnh và lưu vết lịch sử tương tác giữa người dùng và hệ thống.

- conversations: quản lý các phiên hội thoại.
- messages: lưu trữ nội dung trao đổi trong từng phiên hội thoại.

Một phiên hội thoại có thể chứa nhiều tin nhắn, hình thành quan hệ một-nhiều (1) giữa hai bảng.

Nhóm dữ liệu lộ trình: dữ liệu trung tâm, phục vụ việc lưu trữ và quản lý các kế hoạch du lịch được sinh ra bởi hệ thống.

- itineraries: lưu thông tin tổng thể của lộ trình.
- itinerary_days: lưu kế hoạch theo từng ngày.
- itinerary_activities: lưu chi tiết các hoạt động trong từng ngày.

Cấu trúc phân cấp này cho phép biểu diễn đầy đủ một lộ trình du lịch, từ mức tổng quan đến từng hoạt động cụ thể. Mỗi hoạt động được lưu kèm các thông tin như thời gian, địa điểm, tọa độ địa lý, thời lượng và chi phí dự kiến.

Nhóm dữ liệu du lịch: đóng vai trò là nguồn tri thức có cấu trúc phục vụ quá trình gợi ý và xây dựng lộ trình.

- regions: lưu thông tin vùng miền (Miền Bắc, Miền Trung, Miền Nam) và đặc điểm khí hậu.
- provinces: lưu thông tin 34 tỉnh/thành phố trực thuộc Trung ương, bao gồm tọa độ, tháng tham quan lý tưởng và các nhãn phân loại.
- destinations: lưu thông tin các điểm tham quan du lịch (POI) thuộc từng tỉnh, bao gồm tọa độ, giờ mở cửa, giá vé, đánh giá và thời lượng tham quan.
- restaurants: lưu thông tin nhà hàng và địa điểm ẩm thực thuộc từng tỉnh.
- accommodations: lưu thông tin cơ sở lưu trú thuộc từng tỉnh.
- transport_routes: lưu thông tin tuyến di chuyển liên tỉnh, bao gồm phương tiện, thời gian và chi phí.

Bảng 2.4. Các bảng dữ liệu chính trong hệ thống

Bảng	Số trường	Mô tả	Quan hệ chính
users	10	Thông tin tài khoản người dùng	1:N conversations, 1:N itineraries
user_preferences	8	Hồ sơ sở thích du lịch	1:1 users
conversations	5	Phiên hội thoại	N:1 users, 1:N messages
messages	5	Nội dung trao đổi trong hội thoại	N:1 conversations
itineraries	14	Thông tin tổng thể lộ trình	N:1 users, 1:1 conversations
itinerary_days	5	Kế hoạch theo ngày	N:1 itineraries
itinerary_activities	14	Hoạt động trong lộ trình	N:1 itinerary_days
regions	6	Thông tin vùng miền	1:N destinations

provinces	14	Tỉnh/thành phố (34 đơn vị)	N:1 regions
destinations	16	Điểm tham quan du lịch	N:1 destinations
restaurants	13	Nhà hàng và địa điểm ẩm thực	N:1 destinations
accommodations	12	Cơ sở lưu trú	N:1 destinations
transport_routes	12	Tuyến di chuyển giữa các điểm đến	N:1 destinations

Thiết kế dữ liệu theo mô hình quan hệ giúp đảm bảo tính nhất quán giữa các thành phần của hệ thống, đồng thời tạo nền tảng cho các chức năng quản lý người dùng, duy trì hội thoại và xây dựng lộ trình du lịch cá nhân hóa. Bên cạnh dữ liệu quan hệ, hệ thống còn sử dụng dữ liệu vector phục vụ truy xuất ngữ nghĩa.

2.3.2. Cơ sở dữ liệu vector (*pgvector*)

Bên cạnh dữ liệu quan hệ, hệ thống sử dụng extension *pgvector* trên PostgreSQL để lưu trữ vector embedding phục vụ truy xuất ngữ nghĩa trong pipeline RAG. Việc sử dụng chung PostgreSQL cho cả dữ liệu quan hệ và dữ liệu vector giúp đơn giản hóa kiến trúc triển khai, đồng thời thuận lợi hơn trong việc quản lý và đồng bộ dữ liệu.

Các tài liệu trong kho tri thức sau khi được thu thập và chuẩn hóa sẽ được chia thành các đoạn nội dung nhỏ hơn (chunk). Mỗi đoạn văn bản được chuyển đổi thành vector embedding thông qua mô hình nhúng và được lưu trữ cùng với nội dung gốc cũng như các thông tin mô tả liên quan.

Bảng 2.5. Cấu trúc dữ liệu vector embedding

Trường	Kiểu dữ liệu	Mô tả
id	uuid	Khóa định danh của bản ghi vector
content	text	Nội dung văn bản gốc

embedding	vector(3072)	Vector biểu diễn ngữ nghĩa của văn bản
metadata	jsonb	Thông tin mô tả phục vụ lọc và truy xuất

Mô hình nhúng được sử dụng là Gemini Embedding, có nhiệm vụ chuyển đổi nội dung văn bản thành vector biểu diễn ngữ nghĩa. Các vector này cho phép hệ thống tìm kiếm những đoạn thông tin có ý nghĩa tương đồng với truy vấn của người dùng, ngay cả khi truy vấn và tài liệu không sử dụng hoàn toàn cùng từ khóa.

Trong quá trình truy xuất, câu hỏi của người dùng cũng được chuyển đổi thành vector embedding và so sánh với các vector trong kho tri thức bằng độ đo cosine similarity, trong đó pgvector sử dụng chỉ mục HNSW [13] để tăng tốc tìm kiếm láng giềng gần đúng. Những tài liệu có độ tương đồng cao nhất sẽ được lựa chọn làm ứng viên để xây dựng ngữ cảnh đầu vào cho mô hình ngôn ngữ lớn.

Ngoài tìm kiếm theo ngữ nghĩa, hệ thống còn kết hợp lọc theo metadata như loại nguồn dữ liệu, địa điểm, danh mục hoặc ngôn ngữ. Cách tiếp cận này giúp thu hẹp phạm vi tìm kiếm, nâng cao độ chính xác của kết quả truy xuất và giảm lượng ngữ cảnh không liên quan.

2.3.3. *Kho tri thức*

Kho tri thức là nguồn dữ liệu đầu vào của pipeline RAG, cung cấp thông tin để hệ thống truy xuất và sinh lịch trình du lịch. Dữ liệu trong kho tri thức được xây dựng từ nhiều nguồn khác nhau nhằm đảm bảo tính đa dạng, độ bao phủ và khả năng bổ sung thông tin cho bài toán du lịch tại Việt Nam.

Các nguồn dữ liệu chính được sử dụng trong hệ thống bao gồm:


- Dữ liệu biên soạn thủ công: bao gồm thông tin tổng quan về vùng miền, điểm đến tiêu biểu, tuyến vận chuyển, đặc điểm mùa vụ và các nội dung du lịch đã được kiểm duyệt. Nguồn dữ liệu này đóng vai trò làm tập tri thức nền tảng, giúp hệ thống duy trì khả năng tư vấn ngay cả khi các nguồn dữ liệu bên ngoài không khả dụng.

- OpenStreetMap (Overpass API): cung cấp dữ liệu địa lý và các điểm quan tâm (Point of Interest – POI) như điểm tham quan, nhà hàng, khách sạn và cơ sở lưu trú. Dữ liệu thu thập bao gồm tên địa điểm, tọa độ địa lý, loại hình dịch vụ và các thông tin mô tả liên quan. Đây là nguồn dữ liệu quan trọng phục vụ việc xây dựng lịch trình và hiển thị trên bản đồ.
- Wikipedia tiếng Việt và tiếng Anh: cung cấp thông tin mô tả về các địa danh, điểm đến và giá trị văn hóa – lịch sử. Việc sử dụng dữ liệu song ngữ giúp tăng độ bao phủ nội dung, đồng thời hỗ trợ truy xuất thông tin đối với các địa điểm có lượng dữ liệu tiếng Việt còn hạn chế.
- Foursquare Places API: bổ sung dữ liệu POI như nhà hàng, điểm tham quan và địa điểm dịch vụ cho các điểm đến cần làm giàu thêm thông tin. Nguồn này được sử dụng như kênh thu thập bổ sung bên cạnh OpenStreetMap, đặc biệt hữu ích với các địa điểm ẩm thực hoặc dịch vụ mà OpenStreetMap chưa có dữ liệu đầy đủ.

Sau khi thu thập, dữ liệu được chuẩn hóa và xử lý theo quy trình trình bày tại Mục 2.3.4.

2.3.4. Quy trình xử lý dữ liệu

Kho tri thức của hệ thống được xây dựng thông qua một quy trình xử lý dữ liệu thống nhất, từ khâu thu thập dữ liệu đến khi tạo vector embedding phục vụ truy xuất ngữ nghĩa. Quy trình này giúp đảm bảo dữ liệu từ nhiều nguồn khác nhau được chuẩn hóa về cấu trúc, loại bỏ các thông tin không phù hợp và duy trì tính nhất quán trước khi đưa vào sử dụng.



Hình 2.4. Quy trình xử lý dữ liệu

Dữ liệu từ các nguồn đã trình bày ở Mục 2.3.3 được xử lý qua các bước: thu thập, làm sạch, chuẩn hóa, chia đoạn (chunking), sinh embedding và lưu trữ vào cơ sở dữ liệu.

2.4. Thiết kế hệ thống RAG

Hệ thống RAG là thành phần trung tâm, chịu trách nhiệm kết nối kho tri thức với mô hình ngôn ngữ lớn để sinh ra các đề xuất lịch trình có căn cứ dữ liệu. Kiến trúc được xây dựng theo hướng RAG nâng cao (Advanced RAG), trong đó bổ sung nhiều giai đoạn tối ưu nhằm cải thiện chất lượng ngữ cảnh truy xuất và kết quả đầu ra.

2.4.1. RAG cơ bản và RAG nâng cao

Trong kiến trúc RAG cơ bản, quy trình xử lý thường gồm ba bước chính: tiếp nhận truy vấn, truy xuất tài liệu từ kho tri thức và sinh kết quả dựa trên các tài liệu được truy xuất [11]. Cách tiếp cận này có ưu điểm là đơn giản, dễ triển khai, nhưng vẫn tồn tại một số hạn chế khi áp dụng cho bài toán gợi ý du lịch cá nhân hóa:

- Nếu chỉ dựa trên tìm kiếm vector, hệ thống có thể bỏ sót các tài liệu chứa từ khóa đặc thù như tên địa danh, món ăn, loại hình dịch vụ hoặc tuyến di chuyển.

- Thiếu cơ chế đánh giá lại chất lượng tài liệu truy xuất, khiến ngữ cảnh đầu vào có thể chứa thông tin nhiễu hoặc chưa thật sự liên quan.
- Ngữ cảnh đưa vào LLM có thể quá dài hoặc chứa nhiều thông tin không cần thiết, ảnh hưởng đến chất lượng sinh phản hồi.
- Trong triển khai cơ bản, dữ liệu có cấu trúc như giá cả, đánh giá, tọa độ hoặc thời gian di chuyển thường chưa được khai thác đầy đủ.

Để nâng cao chất lượng kết quả, hệ thống áp dụng kiến trúc RAG nâng cao. Thay vì chỉ thực hiện truy xuất và sinh phản hồi, kiến trúc này bổ sung các bước như phân tích truy vấn, kết hợp nhiều phương pháp truy xuất, xếp hạng lại tài liệu, xây dựng ngữ cảnh từ nhiều nguồn dữ liệu và hậu xử lý kết quả đầu ra [7]. Nhờ đó, hệ thống có thể tạo ra các đề xuất phù hợp hơn với nhu cầu người dùng, đồng thời giảm nguy cơ sinh thông tin không chính xác hoặc không có căn cứ.


Bảng 2.6. So sánh RAG cơ bản và RAG nâng cao trong hệ thống

Giai đoạn	RAG cơ bản	RAG nâng cao
Trước truy xuất	Sử dụng trực tiếp truy vấn gốc	Phân tích yêu cầu, trích xuất thực thể và tối ưu truy vấn
Truy xuất	Truy xuất tài liệu bằng một phương pháp chính	Hybrid Search kết hợp tìm kiếm ngữ nghĩa và tìm kiếm từ khóa
Sau truy xuất	Ít hoặc không có xử lý bổ sung	Xếp hạng lại, lọc nhiễu và lựa chọn tài liệu phù hợp
Xây dựng ngữ cảnh	Chủ yếu sử dụng tài liệu truy xuất	Kết hợp tài liệu truy xuất, dữ liệu hệ thống, thông tin thời tiết và hồ sơ người dùng
Sinh kết quả	Prompt đơn giản với ngữ cảnh giới hạn	Prompt có ngữ cảnh mở rộng và ràng buộc theo yêu cầu người dùng
Hậu xử lý	Ít hoặc không có hậu xử lý	Kiểm tra, chuẩn hóa và tối ưu lịch trình đầu ra

Từ các phân tích trên, hệ thống lựa chọn kiến trúc RAG nâng cao để phù hợp với bài toán gợi ý du lịch cá nhân hóa. Các thành phần cụ thể của pipeline RAG được trình bày trong các mục tiếp theo.

2.4.2. Phân tích truy vấn và quản lý ngữ cảnh

Giai đoạn tiền truy xuất có nhiệm vụ phân tích và chuẩn hóa yêu cầu của người dùng trước khi thực hiện truy xuất tri thức. Mục tiêu của giai đoạn này là xây dựng một biểu diễn truy vấn đầy đủ, có ngữ cảnh và phù hợp với đặc thù của bài toán du lịch. Hệ thống sử dụng ba thành phần chính gồm: quản lý ngữ cảnh hội thoại (Memory), NLU và bộ lập kế hoạch truy xuất (RAG Planner).



Hình 2.5. Kiến trúc Query Understanding & Memory

Memory chịu trách nhiệm duy trì ngữ cảnh giữa các lượt tương tác. Thành phần này lưu trữ lịch sử hội thoại gần nhất, theo dõi các thực thể quan trọng như điểm đến, thời gian du lịch, ngân sách và sở thích, đồng thời hỗ trợ phân giải các tham chiếu ngữ cảnh xuất hiện trong hội thoại. Ví dụ, khi người dùng sử dụng các cụm từ như “ở đó” hoặc “chỗ này”, hệ thống có thể dựa trên lịch sử hội thoại để xác định địa điểm tương ứng đã được đề cập trước đó.

NLU xác định ý định của người dùng và trích xuất các thông tin cần thiết cho quá trình truy xuất. Kết quả đầu ra bao gồm ý định, các thực thể liên quan đến chuyến đi và truy vấn tìm kiếm đã được chuẩn hóa. Ngoài ra, thành phần này còn hỗ trợ nhận

diện các trường hợp thiếu thông tin quan trọng để hệ thống chủ động yêu cầu người dùng bổ sung trước khi sinh lịch trình.

RAG Planner lựa chọn chiến lược truy xuất phù hợp dựa trên độ phức tạp của yêu cầu. Đối với các truy vấn đơn giản, hệ thống có thể thực hiện truy xuất trực tiếp trên kho tri thức. Với các yêu cầu xây dựng lịch trình nhiều ngày hoặc liên quan đến nhiều điểm đến, phạm vi truy xuất được mở rộng và tổ chức theo nhiều bước nhằm tăng độ bao phủ thông tin.


Bảng 2.7. Chiến lược truy xuất của RAG Planner

Chiến lược	Điều kiện áp dụng	Đặc điểm
Single Retrieval	Truy vấn đơn giản	Truy xuất trực tiếp trên kho tri thức với phạm vi tìm kiếm tương đối hẹp
Multi-step Retrieval	Yêu cầu lập lịch trình nhiều ngày	Mở rộng truy xuất theo nhiều khía cạnh như điểm đến, hoạt động, chi phí, thời gian và sở thích
Multi-destination Retrieval	Yêu cầu liên quan đến nhiều điểm đến	Truy xuất riêng cho từng điểm đến trước khi tổng hợp kết quả và xây dựng ngữ cảnh chung

Đầu ra của giai đoạn này là truy vấn đã được chuẩn hóa, ngữ cảnh hội thoại và chiến lược truy xuất tương ứng. Các thông tin này được sử dụng làm đầu vào cho giai đoạn truy xuất tri thức ở bước tiếp theo.

2.4.3. Truy xuất tri thức

Giai đoạn truy xuất có nhiệm vụ tìm kiếm và lựa chọn các tài liệu liên quan từ kho tri thức để phục vụ quá trình sinh câu trả lời. Trong hệ thống đề xuất, quá trình truy xuất được thực hiện theo hai bước chính: Hybrid Search và Cross-Encoder Reranking.



Hình 2.6. Kiến trúc giai đoạn Retrieval

Hybrid Search kết hợp đồng thời hai phương pháp tìm kiếm:

- Dense Retrieval: sử dụng vector embedding để tìm các tài liệu có nội dung tương đồng về ngữ nghĩa với truy vấn.
- Sparse Retrieval: sử dụng tìm kiếm từ khóa nhằm tăng khả năng nhận diện tên riêng, địa danh và các thuật ngữ đặc thù.

Kết quả từ hai phương pháp được hợp nhất bằng thuật toán RRF [3]. Điểm số của mỗi tài liệu được tính theo công thức:

$$RRF(d) = \sum_{r \in R} \frac{1}{k + rank_r(d)}$$


Trong đó R là tập các danh sách kết quả truy xuất, $rank_r(d)$ là thứ hạng của tài liệu d trong danh sách r , còn k là hằng số điều hòa.

Sau khi hợp nhất kết quả, hệ thống thực hiện Cross-Encoder Reranking nhằm đánh giá lại mức độ liên quan giữa truy vấn và từng tài liệu. Hệ thống sử dụng một mô hình cross-encoder đa ngôn ngữ có hỗ trợ tiếng Việt. Khác với bi-encoder [15] chỉ so sánh các vector biểu diễn độc lập, cross-encoder xử lý trực tiếp cặp truy vấn và tài liệu để tính toán mức độ liên quan. Các tài liệu có điểm số cao nhất được lựa chọn làm đầu vào cho giai đoạn xây dựng ngữ cảnh.

Đầu ra của giai đoạn truy xuất là tập tài liệu đã được sàng lọc và xếp hạng theo mức độ liên quan, phục vụ cho quá trình xây dựng ngữ cảnh và sinh phản hồi ở các bước tiếp theo.

2.4.4. Tối ưu ngữ cảnh

Giai đoạn tối ưu ngữ cảnh có nhiệm vụ xây dựng và tinh gọn ngữ cảnh đầu vào cho mô hình ngôn ngữ từ các dữ liệu đã được truy xuất. Giai đoạn này gồm hai bước chính: tổng hợp ngữ cảnh đa nguồn (Context Aggregation) và nén ngữ cảnh (Context Compression).



Hình 2.7. Quy trình tối ưu ngữ cảnh

Tổng hợp ngữ cảnh đa nguồn (Context Aggregation). Để xây dựng lịch trình du lịch phù hợp, hệ thống không chỉ sử dụng các tài liệu truy xuất từ kho tri thức mà còn kết hợp thêm dữ liệu có cấu trúc và thông tin cá nhân hóa. Việc tổng hợp nhiều nguồn dữ liệu giúp mô hình ngôn ngữ có đầy đủ thông tin hơn về điểm đến, người dùng và điều kiện thực tế tại thời điểm lập kế hoạch.

Các nguồn dữ liệu được sử dụng gồm:

- Tài liệu truy xuất (Retrieved Documents): các tài liệu đã được truy xuất và xếp hạng từ giai đoạn truy xuất.
- Dữ liệu có cấu trúc (Structured DB): dữ liệu có cấu trúc về điểm tham quan, nhà hàng, cơ sở lưu trú và tuyến vận chuyển.

- Hồ sơ người dùng (User Profile): hồ sơ sở thích và lịch sử tương tác của người dùng.
- Gợi ý cá nhân hóa (Recommendations): danh sách địa điểm được gợi ý theo mức độ phù hợp với người dùng.
- Thông tin thời tiết (Weather): thông tin thời tiết tại điểm đến trong khoảng thời gian dự kiến.

Nén ngữ cảnh (Context Compression). Sau khi tổng hợp, ngữ cảnh đầu vào có thể chứa thông tin trùng lặp, dư thừa hoặc ít liên quan đến truy vấn. Hệ thống áp dụng kỹ thuật nén ngữ cảnh theo hướng trích xuất, chỉ giữ lại các đoạn thông tin có mức độ liên quan cao với yêu cầu của người dùng [9]. Quá trình này giúp giảm kích thước ngữ cảnh, hạn chế chi phí xử lý và đảm bảo dữ liệu đầu vào phù hợp với giới hạn ngữ cảnh của mô hình ngôn ngữ.

Kết quả của giai đoạn tối ưu ngữ cảnh là một tập ngữ cảnh đã được tổng hợp và rút gọn, được sử dụng cho quá trình sinh phản hồi ở giai đoạn tiếp theo.

2.4.5. *Sinh phản hồi và cá nhân hóa*

Giai đoạn này thực hiện việc sinh lịch trình hoặc câu trả lời dựa trên ngữ cảnh đã được xây dựng từ các bước trước. Mô hình Gemini 2.5 Flash nhận ngữ cảnh đã được tổng hợp và tối ưu hóa, sau đó sinh phản hồi phù hợp với từng loại yêu cầu.



Hình 2.8. Giai đoạn Generation & Personalization

Sinh phản hồi (Generation): Sau khi nhận ngữ cảnh đầu vào, mô hình ngôn ngữ tiến hành tạo nội dung tương ứng với từng loại yêu cầu. Đối với các truy vấn lập kế hoạch du lịch, hệ thống sinh lịch trình theo từng ngày kèm thông tin về địa điểm, thời

gian và chi phí dự kiến. Với các truy vấn tra cứu hoặc gợi ý địa điểm, hệ thống trả về danh sách đề xuất hoặc thông tin mô tả phù hợp.

Cá nhân hóa (Personalization): Để hỗ trợ cá nhân hóa kết quả, hồ sơ người dùng được tích hợp vào quá trình sinh phản hồi cùng với dữ liệu truy xuất từ kho tri thức. Các thông tin này không thay thế dữ liệu truy xuất, mà đóng vai trò như các ràng buộc và tiêu chí ưu tiên trong quá trình tạo đề xuất. Dữ liệu phục vụ cá nhân hóa bao gồm:

- Phong cách du lịch.
- Sở thích cá nhân.
- Ưu tiên ẩm thực.
- Lịch sử các điểm đến đã ghé thăm.
- Điểm ưu tiên theo từng danh mục, được cập nhật từ phản hồi và hành vi tương tác của người dùng.

Việc tích hợp các thông tin này giúp hệ thống ưu tiên những địa điểm và hoạt động phù hợp hơn với từng người dùng, từ đó nâng cao mức độ cá nhân hóa của kết quả gợi ý.

Đầu ra có cấu trúc (Structured Output). Để thuận lợi cho việc lưu trữ, hậu xử lý và hiển thị trên giao diện, kết quả được sinh theo một cấu trúc dữ liệu thống nhất.

Bảng 2.8. Cấu trúc đầu ra của hệ thống


Cấp dữ liệu	Nội dung
Lộ trình	Tiêu đề, tổng chi phí, số ngày
Ngày	Thông tin từng ngày trong lộ trình
Hoạt động	Thời gian, địa điểm, mô tả, danh mục, chi phí, tọa độ

Cấu trúc này tương ứng với mô hình dữ liệu lịch trình được trình bày tại Mục 2.3.1 và hỗ trợ các bước hậu xử lý cũng như hiển thị trên giao diện người dùng.

Đầu ra của giai đoạn này là lịch trình hoặc câu trả lời đã được cá nhân hóa, làm đầu vào cho giai đoạn hậu xử lý và đánh giá chất lượng kết quả.

2.4.6. Hậu xử lý

Giai đoạn hậu xử lý được thực hiện sau khi mô hình ngôn ngữ sinh ra kết quả nhằm chuẩn hóa dữ liệu, kiểm tra tính hợp lý của lịch trình và đánh giá chất lượng đầu ra trước khi trả về cho người dùng. Giai đoạn này bao gồm ba bước xử lý chính: tối ưu lịch trình, đánh giá chất lượng và ghi nhận tín hiệu sở thích người dùng.



Hình 2.9. Quy trình hậu xử lý kết quả

Tối ưu lịch trình: Kết quả sinh ra từ mô hình ngôn ngữ có thể chứa các địa điểm chưa được chuẩn hóa hoặc cần được kiểm tra lại về khoảng cách và trình tự di chuyển. Vì vậy, hệ thống thực hiện đối chiếu địa điểm với cơ sở dữ liệu, chuẩn hóa thông tin liên quan và tính toán khoảng cách giữa các điểm trong lịch trình. Các tác vụ chính bao gồm:

- Chuẩn hóa tên địa điểm, danh mục và tọa độ địa lý.
- Tính khoảng cách giữa các điểm trong lịch trình.
- Kiểm tra tính hợp lý của thứ tự di chuyển.
- Hiệu chỉnh thông tin chi phí dự kiến khi cần thiết.

Đánh giá chất lượng kết quả (Quality Evaluation): Sau khi tối ưu lịch trình, hệ thống sử dụng bộ tiêu chí đánh giá để kiểm tra chất lượng kết quả sinh ra. Việc đánh giá được thực hiện dựa trên nhiều tiêu chí khác nhau nhằm phục vụ quá trình giám sát, phân tích và cải thiện hệ thống. Đối với các tiêu chí liên quan đến chất lượng RAG, hệ thống có thể tham khảo cách tiếp cận đánh giá tự động như RAGAS [5].

Bảng 2.9. Các tiêu chí đánh giá chất lượng

Tiêu chí	Mô tả
Mức độ liên quan	Kết quả phù hợp với yêu cầu ban đầu của người dùng

Mức độ đầy đủ	Lịch trình có đủ số ngày và các hoạt động cần thiết
Độ bao phủ thông tin	Kết quả khai thác được thông tin từ nhiều nguồn dữ liệu liên quan
Phù hợp ngân sách	Các hoạt động có thông tin chi phí hợp lý so với ngân sách người dùng
Đa dạng hoạt động	Lịch trình có sự phân bổ giữa nhiều loại hình như tham quan, ẩm thực, nghỉ dưỡng
Nhất quán nội dung	Thời gian, thứ tự hoạt động và thông tin mô tả không mâu thuẫn với nhau
Chất lượng ngữ cảnh	Ngữ cảnh truy xuất có mức độ liên quan phù hợp với truy vấn và điểm đến

Ghi nhận sở thích người dùng: Bên cạnh việc trả kết quả, hệ thống ghi nhận và cập nhật hồ sơ người dùng dựa trên các tín hiệu thu được trong quá trình tương tác. Những thông tin này được sử dụng cho các lần truy vấn tiếp theo nhằm nâng cao mức độ cá nhân hóa của kết quả gợi ý. Các nguồn dữ liệu cập nhật bao gồm:

- Các sở thích được người dùng đề cập trực tiếp.
- Các địa điểm và hoạt động được người dùng lựa chọn.
- Phản hồi đánh giá đối với lịch trình.
- Lịch sử tương tác trong hội thoại.

Kết quả của giai đoạn hậu xử lý là lịch trình hoặc câu trả lời đã được chuẩn hóa, kiểm tra chất lượng và bổ sung các tín hiệu cá nhân hóa cần thiết trước khi trả về giao diện người dùng.

2.5. Kết luận chương 2

Chương 2 đã trình bày quá trình phân tích bài toán và thiết kế hệ thống gợi ý lịch trình du lịch cá nhân hóa. Nội dung chính của chương bao gồm:

- Xác định bài toán, đối tượng người dùng, phạm vi nghiên cứu và các yêu cầu chức năng, phi chức năng của hệ thống.

- Thiết kế kiến trúc tổng thể theo mô hình ba tầng gồm tầng giao diện, tầng xử lý nghiệp vụ và tầng dữ liệu, đồng thời tổ chức các thành phần xử lý theo hướng module hóa nhằm tăng tính linh hoạt và khả năng mở rộng.
- Xây dựng cơ sở dữ liệu và kho tri thức, bao gồm quy trình thu thập, chuẩn hóa, chia đoạn và chuyển đổi dữ liệu từ các nguồn như OpenStreetMap, Wikipedia và dữ liệu biên soạn thủ công thành vector embedding phục vụ truy xuất ngữ nghĩa.
- Đề xuất hệ thống RAG nâng cao với các bước: phân tích truy vấn, truy xuất tri thức, tối ưu ngữ cảnh, sinh phản hồi có cá nhân hóa và hậu xử lý kết quả.
- Tích hợp các kỹ thuật như Hybrid Search, Cross-Encoder Reranking, Context Compression, Structured Output và ghi nhận sở thích người dùng nhằm cải thiện chất lượng truy xuất, độ tin cậy của phản hồi và mức độ phù hợp của lịch trình.

Các nội dung đã trình bày trong Chương 2 là cơ sở để triển khai hệ thống thực nghiệm, tiến hành đánh giá và phân tích kết quả trong Chương 3, qua đó kiểm chứng tính khả thi của phương pháp đề xuất.

Chương 3: THỰC NGHIỆM VÀ ĐÁNH GIÁ KẾT QUẢ

3.1. Thiết lập thực nghiệm

3.1.1. Mục tiêu và phương pháp

Mục tiêu của phần thực nghiệm là kiểm tra tính khả thi và đánh giá hiệu quả của hệ thống gợi ý lịch trình du lịch cá nhân hóa dựa trên LLM và RAG đã được thiết kế ở Chương 2. Cụ thể, thực nghiệm tập trung làm rõ khả năng truy xuất tri thức, chất lượng phản hồi sinh ra, mức độ phù hợp của lịch trình với nhu cầu người dùng, hiệu quả của thành phần cá nhân hóa và thời gian xử lý của toàn bộ quy trình.

Luận văn kết hợp hai hướng đánh giá chính:

- Đánh giá định lượng: đo lường chất lượng truy xuất và sinh phản hồi thông qua các chỉ số RAGAS, đồng thời ghi nhận thời gian xử lý ở từng bước trong quy trình.
- Đánh giá định tính: xem xét tính hợp lý, khả thi và mức độ phù hợp của lộ trình du lịch trong các tình huống sử dụng cụ thể.

Các nội dung đánh giá chính được tổng hợp trong Bảng 3.1.

Bảng 3.1. Mục tiêu và phương pháp đánh giá thực nghiệm

Nội dung đánh giá	Mục tiêu	Phương pháp thực hiện
Hệ thống RAG	Đánh giá chất lượng truy xuất tri thức và sinh phản hồi	Sử dụng các chỉ số RAGAS và so sánh giữa các cấu hình RAG
Lịch trình du lịch	Kiểm tra tính đầy đủ, hợp lý và khả thi của lịch trình	Sử dụng bộ tiêu chí đánh giá chất lượng lịch trình
Cá nhân hóa	Xác định ảnh hưởng của hồ sơ người dùng đến kết quả gợi ý	So sánh kết quả khi có và không có thông tin cá nhân hóa

Hiệu năng hệ thống	Đo thời gian xử lý và khả năng phản hồi của hệ thống	Ghi nhận thời gian xử lý theo từng bước trong quy trình và tổng thời gian phản hồi
--------------------	--	--

Bên cạnh cấu hình đầy đủ, luận văn cũng so sánh với các cấu hình rút gọn nhằm làm rõ mức độ đóng góp của từng thành phần trong hệ thống. Các cấu hình RAG, bộ tiêu chí đánh giá lịch trình, thí nghiệm cá nhân hóa, bộ dữ liệu thực nghiệm và kịch bản đánh giá cụ thể được trình bày trong các phần tiếp theo.

3.1.2. Môi trường thực nghiệm và cấu hình đánh giá

Hệ thống thực nghiệm được triển khai trên môi trường phát triển cục bộ. Cấu hình phần cứng, phần mềm và các thành phần chính được trình bày trong Bảng 3.2.

Bảng 3.2. Môi trường phần cứng và phần mềm

Thành phần	Cấu hình
Hệ điều hành	macOS 26.5
CPU	Apple M3 Pro
RAM	18 GB
Backend	Python 3.13
Frontend	Node.js 22.17
Cơ sở dữ liệu	PostgreSQL 16 + pgvector (Docker)
Bộ nhớ đệm	Redis 7 (Docker)

Bên cạnh môi trường triển khai, hệ thống sử dụng các mô hình và cấu hình RAG như trong Bảng 3.3.

Bảng 3.3. Cấu hình mô hình và hệ thống RAG

Thành phần	Cấu hình
Mô hình ngôn ngữ lớn	Gemini 2.5 Flash
Mô hình embedding	Gemini Embedding
Mô hình reranking	BAAI/bge-reranker-v2-m3
Tham số sinh phản hồi	temperature = 0.3
Truy xuất	Dense Search, Hybrid Search, Reranking tùy cấu hình thử nghiệm
Nén ngữ cảnh	Extractive Compression

Thời gian phản hồi được ghi nhận từ thời điểm hệ thống tiếp nhận truy vấn đến khi trả về kết quả hoàn chỉnh cho người dùng. Các cấu hình thử nghiệm được thực hiện trên cùng một môi trường nhằm đảm bảo tính so sánh giữa các kết quả.

3.1.3. Bộ dữ liệu thực nghiệm

Dữ liệu nền được sử dụng làm nguồn tri thức cho hệ thống RAG, bao gồm thông tin về các điểm đến du lịch tại Việt Nam. Dữ liệu được thu thập từ OpenStreetMap, Wikipedia song ngữ Việt – Anh và dữ liệu biên soạn thủ công, sau đó được chuẩn hóa và lưu trữ trong PostgreSQL kết hợp pgvector.

Bảng 3.4. Thống kê dữ liệu kho tri thức

Loại dữ liệu	Số lượng	Ghi chú
Tỉnh/thành phố	34	100% có tọa độ, tháng tham quan lý tưởng và nhãn phân loại
Điểm tham quan	4.401	100% có tọa độ, giờ mở cửa, giá vé và đánh giá
Nhà hàng	15.878	99,9% có tọa độ

Chỗ ở	6.774	99,7% có tọa độ
Tuyến giao thông	104	100% có chi phí ước tính và thời gian di chuyển
Tổng POI	27.053	Điểm tham quan, nhà hàng và chỗ ở
Tổng bản ghi du lịch	27.194	Bao gồm POI và tuyến giao thông

Tập truy vấn thực nghiệm gồm 50 câu hỏi được xây dựng thủ công, bao phủ bốn nhóm yêu cầu: lập lịch trình, gợi ý điểm đến, tra cứu thông tin và hội thoại chung. Chi tiết các nhóm truy vấn và kịch bản đánh giá được trình bày ở phần tiếp theo.

3.1.4. Kịch bản thực nghiệm

Thực nghiệm được tổ chức thành bốn kịch bản, mỗi kịch bản tập trung vào một khía cạnh chất lượng khác nhau của hệ thống. Chi tiết phương pháp đánh giá và kết quả của từng kịch bản được trình bày tại Mục 3.3.

Bảng 3.5. Kịch bản thực nghiệm

Kịch bản	Nội dung	Chỉ số đo lường chính
Hiểu ngôn ngữ tự nhiên	Đánh giá thành phần NLU trên 50 truy vấn thực nghiệm	Độ chính xác phân loại ý định, trích xuất điểm đến và trích xuất thời lượng chuyến đi
Hệ thống RAG end-to-end	Chạy toàn bộ hệ thống trên tập truy vấn đại diện	Tính đầy đủ, độ đa dạng, tính hợp lý về thời gian, bao phủ chi phí, chất lượng tọa độ và thời gian phản hồi
So sánh các cấu hình	So sánh kết quả giữa RAG đầy đủ và các cấu hình rút gọn như LLM thuần, Basic RAG	Điểm chất lượng tổng hợp, độ chính xác POI, chi phí, tọa độ và thời gian phản hồi

Cá nhân hóa	So sánh kết quả khi có và không có hồ sơ người dùng	Mức độ phù hợp với sở thích, khả năng đáp ứng ràng buộc ngân sách và tính hợp lý của lịch trình
-------------	---	---

3.2. Xây dựng hệ thống thực nghiệm

Hệ thống thực nghiệm được triển khai dựa trên thiết kế đã trình bày ở Chương 2, bao gồm các thành phần xử lý truy vấn, truy xuất dữ liệu, sinh lịch trình, cá nhân hóa và hiển thị kết quả đầu ra.

3.2.1. Tổng quan các thành phần triển khai

Các chức năng chính của hệ thống được triển khai nhằm hỗ trợ toàn bộ quá trình từ tiếp nhận truy vấn ngôn ngữ tự nhiên đến trả về kết quả gợi ý du lịch cho người dùng.

Bảng 3.6. Thành phần triển khai trong hệ thống thực nghiệm

Thành phần	Nội dung triển khai
Giao diện hội thoại	Cho phép người dùng nhập yêu cầu du lịch bằng ngôn ngữ tự nhiên và nhận kết quả gợi ý
Xử lý truy vấn	Trích xuất ý định, điểm đến, thời lượng chuyến đi, ngân sách và sở thích từ câu truy vấn
Truy xuất dữ liệu	Tìm kiếm thông tin liên quan từ kho tri thức du lịch bằng dense search, hybrid search và reranking tùy theo cấu hình thử nghiệm
Sinh lịch trình	Tạo lịch trình theo ngày, bao gồm địa điểm, hoạt động, thời gian và chi phí ước tính
Cá nhân hóa	Sử dụng hồ sơ người dùng và phản hồi trước đó để điều chỉnh kết quả gợi ý
Hiển thị bản đồ	Trực quan hóa tọa độ các điểm đến, nhà hàng và cơ sở lưu trú trên giao diện

Bộ nhớ đệm	Lưu tạm một số kết quả truy vấn nhằm giảm thời gian xử lý ở các lần truy cập sau
------------	--

3.2.2. Một số điểm triển khai đáng chú ý

Trong quá trình xây dựng hệ thống thực nghiệm, một số kỹ thuật được áp dụng nhằm cải thiện tốc độ xử lý, khả năng mở rộng và chất lượng phản hồi. Các điểm triển khai đáng chú ý gồm:

- Tổ chức backend theo nhóm dịch vụ: backend được tách thành các nhóm chức năng chính, bao gồm:
 - + Xác thực người dùng.
 - + Quản lý hội thoại.
 - + Xử lý ngôn ngữ tự nhiên.
 - + Truy xuất tri thức.
 - + Sinh lịch trình.
 - + Quản lý hồ sơ người dùng.
 - + Thu thập phản hồi.
- Xử lý song song trong giai đoạn truy xuất: hệ thống sử dụng `asyncio.gather()` để thực hiện đồng thời các tác vụ:
 - + Tìm kiếm vector.
 - + Truy vấn cơ sở dữ liệu.
 - + Tra cứu thông tin thời tiết.
 - + Lấy các gợi ý liên quan.
- Tái sử dụng mô hình reranking: mô hình BAAI/bge-reranker-v2-m3 được khởi tạo một lần khi hệ thống bắt đầu hoạt động và tái sử dụng cho các truy vấn tiếp theo, giúp giảm chi phí tải lại mô hình.
- Sinh lịch trình theo hai giai đoạn: với các yêu cầu lập lịch trình dài hơn 3 ngày, hệ thống sinh kết quả theo hai bước:
 - + Giai đoạn 1: xây dựng khung lịch trình tổng quát.
 - + Giai đoạn 2: bổ sung chi tiết cho từng ngày.
- Chuẩn hóa và bổ sung kết quả đầu ra: trước khi trả về giao diện, hệ thống đối chiếu và bổ sung các thông tin cần thiết, bao gồm:


- + Tọa độ địa lý.
- + Chi phí ước tính.
- + Thông tin thời tiết.
- + Dữ liệu di chuyển giữa các điểm.

3.2.3. *Kết quả đầu ra của hệ thống*

Kết quả trả về cho người dùng được tổ chức theo một cấu trúc thống nhất nhằm đảm bảo tính nhất quán giữa các lần thử nghiệm và thuận tiện cho việc lưu trữ, hiển thị cũng như đánh giá kết quả.

Bảng 3.7. Thành phần kết quả đầu ra

Thành phần	Nội dung
Lịch trình theo ngày	Danh sách hoạt động, địa điểm, thời gian và chi phí ước tính
Địa điểm gợi ý	Danh sách điểm tham quan, nhà hàng hoặc cơ sở lưu trú phù hợp với truy vấn
Bản đồ	Tọa độ các địa điểm được đề xuất
Thông tin bổ sung	Thời tiết, phương tiện di chuyển và ghi chú cần thiết
Phản hồi hội thoại	Câu trả lời tự nhiên, có giải thích ngắn gọn theo yêu cầu người dùng



Hình 3.1. Giao diện hội thoại

3.3. Kết quả và đánh giá

Kết quả thực nghiệm được tổng hợp theo bốn kịch bản: phân tích truy vấn người dùng, đánh giá chất lượng lịch trình end-to-end, so sánh các cấu hình RAG và đánh giá khả năng cá nhân hóa.

3.3.1. Đánh giá phân tích truy vấn người dùng

Đánh giá khả năng phân loại ý định và trích xuất thực thể được thực hiện trên tập 50 truy vấn mẫu. Do đặc thù của ngôn ngữ tự nhiên, không phải truy vấn nào cũng chứa đầy đủ mọi thông tin. Tập dữ liệu đánh giá thực tế bao gồm:

- Phân loại ý định: 50/50 truy vấn.
- Trích xuất điểm đến: 36 truy vấn có chứa thông tin địa danh.
- Trích xuất thời lượng: 26 truy vấn có đề cập thời gian (vd: "3 ngày", "cuối tuần").
- Trích xuất ngân sách: 6 truy vấn có yếu tố chi phí (vd: "5 triệu").

Bảng 3.8. Kết quả đánh giá phân tích truy vấn

Chỉ số	Kết quả	Nhận xét
Độ chính xác phân loại ý định	94,0%	Hệ thống nhận diện tốt các nhóm truy vấn phổ biến; 3 lỗi xảy ra khi truy vấn chứa đồng thời keyword thuộc nhiều nhóm ý định
Độ chính xác trích xuất điểm đến	100%	Toàn bộ 36 truy vấn có nêu điểm đến đều được nhận diện chính xác
Độ chính xác trích xuất thời lượng chuyển đi	100%	Các biểu thức như “3 ngày”, “4 ngày 3 đêm”, “2 ngày 1 đêm” được xử lý chính xác
Độ chính xác trích xuất ngân sách	100%	Các ràng buộc ngân sách dạng “X triệu” được trích xuất chính xác

Kết quả cho thấy thành phần phân tích truy vấn đáp ứng được yêu cầu đầu vào của hệ thống. Các thông tin như ý định, điểm đến, thời lượng chuyển đi và ngân sách được chuyển thành cấu trúc dữ liệu rõ ràng, phục vụ cho các bước truy xuất tri thức và sinh lịch trình ở phía sau.

3.3.2. Đánh giá chất lượng lộ trình end-to-end

Chất lượng lịch trình được đánh giá theo hướng kiểm tra mức độ thỏa mãn ràng buộc đầu vào. Với mỗi truy vấn, hệ thống cần sinh ra lịch trình đáp ứng các yêu cầu mà người dùng đã nêu. Năm truy vấn đại diện được lựa chọn, bao phủ các kịch bản phổ biến như du lịch biển, gia đình có trẻ em, du lịch tiết kiệm, văn hóa – lịch sử và nghỉ dưỡng cao cấp.

Các ràng buộc được kiểm tra bao gồm:

- Số ngày: lịch trình sinh ra có đúng thời lượng chuyển đi được yêu cầu hay không.
- Ngân sách: tổng chi phí có nằm trong giới hạn ngân sách hay không, với mức sai lệch chấp nhận không vượt quá 20%.

- Sở thích: các hoạt động có phản ánh đúng sở thích đã nêu hay không, được kiểm tra thông qua đối chiếu từ khóa.
- Điểm đến: các POI có thuộc đúng tỉnh/thành phố được yêu cầu hay không.
- Đối tượng: lịch trình có phù hợp với nhóm du lịch được nêu trong truy vấn hay không, chẳng hạn như gia đình, trẻ em hoặc cặp đôi.

Bảng 3.9. Kết quả đánh giá lịch trình theo ràng buộc đầu vào

STT	Truy vấn	Số ngày	Ngân sách	Sở thích	Điểm đến	Đối tượng	Hoạt động	Thời gian
1	Đà Nẵng 3N2Đ, 5tr, biển + âm thực	3/3	3,77tr/ 5tr	Biển, âm thực	Đà Nẵng	—	24 (8,0/ngà y)	90,0s
2	Phú Quốc 4N, gia đình, trẻ em	4/4	—	—	Phú Quốc	VinWonders , bãi biển, công viên	34 (8,5/ngà y)	131,4 s
3	Nha Trang 3N, tiết kiệm, <3tr	3/3	2,02tr/ 3tr	—	Nha Trang	—	22 (7,3/ngà y)	92,8s

4	Hà Nội 3N, gia đình, lịch sử + ẩm thực	3/3	—	Lịch sử, ẩm thực	Hà Nội	Bảo tàng, hồ, công viên	24 (8,0/ngày)	91,0s
5	Phú Quốc 5N, luxury, cặp đôi, 20tr	5/5	19,66tr /20tr	Nghỉ dưỡng cao cấp	Phú Quốc	Sunset, dinner lãng mạn	35 (7,0/ngày)	131,6s
	Tổng kết	5/5	3/3	3/3	5/5	3/3		TB 107,4s

Từ kết quả Bảng 3.9, có thể rút ra một số nhận xét:

- Số ngày: 5/5 lịch trình sinh đúng số ngày yêu cầu.
- Ngân sách: 3/3 truy vấn có ràng buộc ngân sách đều cho tổng chi phí nằm trong giới hạn cho phép.
- Sở thích và đối tượng: các hoạt động phản ánh đúng sở thích và nhóm du lịch đã nêu trong truy vấn.
- Điểm đến: 5/5 lịch trình tập trung đúng tỉnh/thành phố được yêu cầu.
- Hoạt động: hệ thống sinh tổng cộng 139 hoạt động, trung bình từ 7,0 đến 8,5 hoạt động/ngày.

- Thời gian phản hồi: thời gian trung bình đạt 107,4 giây; lịch trình 5 ngày cao cấp mất nhiều thời gian nhất, đạt 131,6 giây do kích hoạt cơ chế sinh hai giai đoạn đã trình bày tại Mục 3.2.2.

3.3.3. So sánh các cấu hình RAG

Để xác định mức độ đóng góp của từng thành phần, luận văn so sánh cấu hình đầy đủ với các cấu hình rút gọn. Các cấu hình được đánh giá dựa trên một số chỉ số RAGAS và thời gian phản hồi trung bình.

Bảng 3.10. Kết quả so sánh các cấu hình RAG

Cấu hình	Context Precision	Context Recall	Faithfulness	Answer Relevancy	Thời gian TB
LLM	N/A	N/A	0,00	1,00	40,4s
RAG cơ bản	0,50	1,00	1,00	1,00	95,5s
RAG nâng cao	0,32	0,62	1,00	1,00	83,9s

Từ kết quả Bảng 3.10, có thể rút ra một số nhận xét:

- Faithfulness: LLM đạt 0,00 do một số POI được sinh ra không khớp với kho tri thức. Khi bổ sung RAG, chỉ số này tăng lên 1,00, cho thấy truy xuất tri thức giúp phản hồi bám sát dữ liệu hơn.
- Context Precision và Context Recall: RAG nâng cao có giá trị thấp hơn RAG cơ bản do quá trình reranking và nén ngữ cảnh làm giảm số lượng tài liệu đầu vào. Điều này cho thấy ngữ cảnh được rút gọn hơn, nhưng mức độ bao phủ theo thước đo RAGAS chưa cao bằng RAG cơ bản.
- Thời gian phản hồi: LLM có thời gian xử lý thấp nhất, đạt 40,4 giây, do không thực hiện truy xuất dữ liệu. RAG nâng cao đạt 83,9 giây, thấp hơn RAG cơ bản 95,5 giây nhờ nén ngữ cảnh giúp giảm kích thước prompt đầu vào.
- Answer Relevancy: Cả ba cấu hình đều đạt 1,00, cho thấy các lịch trình sinh ra vẫn phù hợp với điểm đến, thời lượng chuyển đi và loại hình yêu cầu trong truy vấn.

3.3.4. *Đánh giá khả năng cá nhân hóa*

Để đánh giá ảnh hưởng của thành phần cá nhân hóa, luận văn tiến hành thực nghiệm với hai người dùng gửi cùng một truy vấn trung lập, tức là truy vấn chỉ nêu điểm đến và thời gian, không nêu sở thích hay ngân sách cụ thể. Sự khác biệt trong kết quả chủ yếu đến từ hồ sơ người dùng được lưu trong cơ sở dữ liệu:

- Người dùng A: tài khoản mới, chưa có hồ sơ sở thích.
- Người dùng B: có hồ sơ gồm phong cách du lịch tiết kiệm, sở thích ẩm thực, biển và văn hóa địa phương.

Bảng 3.11. So sánh kết quả có và không có cá nhân hóa

Truy vấn	Người dùng	Ngân sách ước tính	% Ẩm thực	% Tham quan	Ghi chú
Đà Nẵng 3 ngày	A	5.980.000đ	47,1%	29,4%	Mức chi phí trung bình
Đà Nẵng 3 ngày	B	2.430.000đ	47,1%	23,5%	Gợi ý ghi “phù hợp phong cách tiết kiệm”
Hà Nội 3 ngày	A	4.070.000đ	52,4%	28,6%	Lịch trình tổng quát
Hà Nội 3 ngày	B	2.950.000đ	45,0%	35,0%	Bổ sung Bảo tàng Dân tộc học

Từ kết quả Bảng 3.11, có thể rút ra một số nhận xét:

- Không có hồ sơ: Người dùng A nhận lịch trình phân bổ tương đối đều giữa các loại hình, với gợi ý nhà hàng mang tính chung.
- Có hồ sơ: Người dùng B được ưu tiên trải nghiệm ẩm thực và văn hóa; tỷ lệ tham quan tăng và có bổ sung điểm đến phù hợp như Bảo tàng Dân tộc học.
- Ngân sách phản ánh phong cách: Chi phí của người dùng B thấp hơn rõ rệt (Đà Nẵng: 5,98 → 2,43 triệu; Hà Nội: 4,07 → 2,95 triệu), cho thấy ảnh hưởng của hồ sơ “du lịch tiết kiệm”.

3.3.5. Tổng hợp kết quả đánh giá

Sau khi đánh giá từng kịch bản thực nghiệm, kết quả được tổng hợp nhằm làm rõ hiệu quả của hệ thống trên các khía cạnh chính: phân tích truy vấn, chất lượng lịch trình, cấu hình RAG và cá nhân hóa.

Bảng 3.12. Tổng hợp kết quả theo bốn kịch bản thực nghiệm

Kịch bản	Kết quả chính	Hạn chế
Phân tích truy vấn	Nhận diện được ý định, điểm đến, số ngày, sở thích và đối tượng du lịch trong các truy vấn rõ ràng	Còn phụ thuộc vào từ khóa và biểu thức chính quy, xử lý chưa tốt các truy vấn mơ hồ
Chất lượng lịch trình	Lịch trình có cấu trúc đầy đủ gồm thời gian, địa điểm, chi phí và tọa độ; các ràng buộc đầu vào được đáp ứng trong 5 truy vấn đại diện	Truy vấn có nhiều ràng buộc đồng thời có thể làm giảm tính hợp lý của lịch trình
So sánh cấu hình RAG	RAG nâng cao giữ Faithfulness ở mức 1,00 và giảm khoảng 12% thời gian so với RAG cơ bản nhờ nén ngữ cảnh	Context Precision và Context Recall thấp hơn do reranking và nén ngữ cảnh làm giảm số lượng tài liệu đầu vào
Cá nhân hóa	Lịch trình phản ánh hồ sơ người dùng rõ hơn, đặc biệt ở lựa chọn nhà hàng, loại hình trải nghiệm và ngân sách	Hiệu quả phụ thuộc vào mức độ đầy đủ của hồ sơ người dùng

Bảng 3.13. Tổng hợp thời gian phản hồi của hệ thống

Nội dung đo lường	Giá trị	Nhận xét
Thời gian phản hồi trung bình của RAG nâng cao	83,9 giây	Trung bình trên 3 truy vấn trong thí nghiệm so sánh cấu hình
Thời gian phản hồi thấp nhất	29,5 giây	Giá trị nhỏ nhất trong 3 lần chạy LLM thuần với truy vấn đơn giản

Thời gian phản hồi cao nhất	131,6 giây	Lịch trình 5 ngày kích hoạt cơ chế sinh hai giai đoạn
LLM thuần	40,4 giây	Nhanh nhất nhưng không đảm bảo dữ liệu sinh ra khớp với kho tri thức
RAG cơ bản	95,5 giây	Giữ nhiều tài liệu truy xuất hơn, làm tăng kích thước đầu vào cho mô hình
RAG nâng cao	83,9 giây	Nén ngữ cảnh giúp giảm kích thước đầu vào và rút ngắn thời gian xử lý

Kết quả tổng hợp cho thấy hệ thống đạt kết quả khả quan trong bài toán gợi ý lịch trình du lịch cá nhân hóa. So với LLM thuần, cấu hình RAG nâng cao giúp phản hồi bám sát kho tri thức hơn. So với RAG cơ bản, cấu hình này có thời gian xử lý thấp hơn nhờ cơ chế nén ngữ cảnh. Tuy nhiên, thời gian phản hồi vẫn còn tương đối cao đối với các truy vấn lập lịch trình dài hoặc có nhiều ràng buộc, do đó cần tiếp tục được tối ưu trong các phiên bản sau.

3.4. Kết luận chương 3

Chương 3 đã trình bày quá trình thực nghiệm và đánh giá hệ thống gợi ý lịch trình du lịch cá nhân hóa theo bốn kịch bản: phân tích truy vấn, đánh giá chất lượng lịch trình end-to-end, so sánh các cấu hình RAG và đánh giá khả năng cá nhân hóa.

Các kết quả chính đạt được gồm:

- Hệ thống nhận diện được ý định, điểm đến, số ngày và sở thích từ các truy vấn tự nhiên trong các trường hợp rõ ràng.
- Lịch trình sinh ra có cấu trúc đầy đủ, bao gồm thời gian, địa điểm, chi phí và tọa độ; khi sử dụng RAG, chỉ số Faithfulness đạt 1,00 trong thí nghiệm so sánh cấu hình.
- Cấu hình RAG nâng cao, bao gồm Hybrid Search, Reranking và nén ngữ cảnh, giữ được chất lượng phản hồi ổn định, đồng thời giảm khoảng 12% thời gian xử lý so với RAG cơ bản.

- Thành phần cá nhân hóa giúp lịch trình phản ánh rõ hơn hồ sơ người dùng, thể hiện qua việc gợi ý nhà hàng cụ thể hơn và điều chỉnh ngân sách theo phong cách du lịch tiết kiệm.

Bên cạnh các kết quả đạt được, hệ thống vẫn còn một số hạn chế:

- Thời gian phản hồi còn tương đối cao, đặc biệt với các truy vấn lập lịch trình dài hoặc có nhiều ràng buộc.
- Thành phần phân tích truy vấn vẫn phụ thuộc vào từ khóa và biểu thức chính quy, nên chưa xử lý tốt các truy vấn mơ hồ hoặc diễn đạt phức tạp.
- Hiệu quả cá nhân hóa phụ thuộc vào mức độ đầy đủ của hồ sơ người dùng.

Tổng thể, kết quả thực nghiệm cho thấy hướng tiếp cận kết hợp LLM và RAG có tính khả thi đối với bài toán gợi ý lịch trình du lịch cá nhân hóa tại Việt Nam. Các hạn chế đã chỉ ra cũng là cơ sở cho việc đề xuất hướng phát triển trong phần kết luận của luận văn.

KẾT LUẬN

Qua quá trình nghiên cứu và thực nghiệm, luận văn đã tiếp cận bài toán gợi ý lịch trình du lịch cá nhân hóa tại Việt Nam bằng cách kết hợp mô hình ngôn ngữ lớn với kỹ thuật Retrieval-Augmented Generation. Từ những khoảng trống còn tồn tại trong các hệ thống hiện có, nghiên cứu đã đề xuất một kiến trúc RAG nâng cao với quy trình xử lý gồm phân tích ý định, truy xuất tri thức, tối ưu ngữ cảnh, sinh lịch trình có cấu trúc và áp dụng cá nhân hóa theo hồ sơ người dùng.

Kết quả thực nghiệm cho thấy phương pháp đề xuất đạt được những kết quả khả quan. Các lịch trình được tạo ra có cấu trúc tương đối đầy đủ, bao gồm thời gian, địa điểm, chi phí và tọa độ, đồng thời bám sát dữ liệu từ kho tri thức khi sử dụng RAG. Việc áp dụng RAG nâng cao kết hợp với cơ chế nén ngữ cảnh giúp hệ thống cân bằng tốt hơn giữa chất lượng phản hồi và thời gian xử lý. Bên cạnh đó, thành phần cá nhân hóa cho thấy tác dụng trong việc điều chỉnh kết quả theo hồ sơ người dùng, thể hiện qua sự khác biệt về lựa chọn điểm đến, nhà hàng, hoạt động và mức ngân sách giữa các nhóm người dùng khác nhau.

Tuy nhiên, hệ thống vẫn còn một số hạn chế cần tiếp tục cải thiện. Thời gian phản hồi còn tương đối cao do phụ thuộc vào API bên ngoài và quy trình xử lý gồm nhiều bước. Hướng khắc phục có thể là tối ưu quy trình, áp dụng cơ chế streaming để cải thiện trải nghiệm người dùng hoặc sử dụng các mô hình nhỏ hơn cho một số tác vụ phù hợp. Ngoài ra, thành phần phân tích truy vấn hiện vẫn phụ thuộc một phần vào từ khóa và biểu thức chính quy, nên chưa xử lý tốt các yêu cầu mơ hồ hoặc diễn đạt phức tạp. Trong tương lai, hệ thống cần được mở rộng kho tri thức, bổ sung dữ liệu cập nhật hơn và thử nghiệm với người dùng thực tế để cải thiện chất lượng gợi ý cũng như khả năng cá nhân hóa.

DANH MỤC CÁC TÀI LIỆU THAM KHẢO

❖ Tài liệu tiếng Việt

- [1]. Thủ tướng Chính phủ (2020), “Quyết định số 147/QĐ-TTg ngày 22/01/2020 phê duyệt Chiến lược phát triển du lịch Việt Nam đến năm 2030”, Hà Nội, Việt Nam.

❖ Tài liệu tiếng Anh

- [2]. Brown T. et al. (2020), “Language Models are Few-Shot Learners”, *Advances in Neural Information Processing Systems*, 33, pp. 1877–1901.
- [3]. Cormack G. V., Clarke C. L. A. and Buettcher S. (2009), "Reciprocal Rank Fusion Outperforms Condorcet and Individual Rank Learning Methods", *Proceedings of the 32nd International ACM SIGIR Conference on Research and Development in Information Retrieval*, pp. 758–759.
- [4]. Devlin J. et al. (2019), “BERT: Pre-training of Deep Bidirectional Transformers for Language Understanding”, *Proceedings of NAACL-HLT*, pp. 4171–4186.
- [5]. Es S. et al. (2024), “RAGAs: Automated Evaluation of Retrieval Augmented Generation”, *Proceedings of the 18th Conference of the European Chapter of the Association for Computational Linguistics: System Demonstrations*, pp. 150–158.
- [6]. Gao Y. et al. (2023), “Chat-Rec: Towards Interactive and Explainable LLMs-Augmented Recommender System”, *arXiv preprint arXiv:2303.14524*.
- [7]. Gao Y. et al. (2023), “Retrieval-Augmented Generation for Large Language Models: A Survey”, *arXiv preprint arXiv:2312.10997*, revised 2024.
- [8]. Gemini Team et al. (2023), “Gemini: A Family of Highly Capable Multimodal Models”, *arXiv preprint arXiv:2312.11805*.
- [9]. Jiang H. et al. (2024), “LongLLMLingua: Accelerating and Enhancing LLMs in Long Context Scenarios via Prompt Compression”, *Proceedings of the 62nd Annual Meeting of the Association for Computational Linguistics*, pp. 1658–1677.

- [10]. Karpukhin V. et al. (2020), “Dense Passage Retrieval for Open-Domain Question Answering”, *Proceedings of EMNLP*, pp. 6769–6781.
- [11]. Lewis P. et al. (2020), “Retrieval-Augmented Generation for Knowledge-Intensive NLP Tasks”, *Advances in Neural Information Processing Systems*, 33, pp. 9459–9474.
- [12]. Luan Y., Eisenstein J., Toutanova K. and Collins M. (2021), "Sparse, Dense, and Attentional Representations for Text Retrieval", *Transactions of the Association for Computational Linguistics*, 9, pp. 329–345.
- [13]. Malkov Y. A. and Yashunin D. A. (2020), “Efficient and Robust Approximate Nearest Neighbor Search Using Hierarchical Navigable Small World Graphs”, *IEEE Transactions on Pattern Analysis and Machine Intelligence*, 42(4), pp. 824–836.
- [14]. Nogueira R. and Cho K. (2019), “Passage Re-ranking with BERT”, *arXiv preprint arXiv:1901.04085*.
- [15]. Reimers N. and Gurevych I. (2019), “Sentence-BERT: Sentence Embeddings using Siamese BERT-Networks”, *Proceedings of EMNLP-IJCNLP*, pp. 3982–3992.
- [16]. Ricci F., Rokach L. and Shapira B., Eds. (2015), *Recommender Systems Handbook*, 2nd ed., Springer, New York, United States.
- [17]. Robertson S. and Zaragoza H. (2009), “The Probabilistic Relevance Framework: BM25 and Beyond”, *Foundations and Trends in Information Retrieval*, 3(4), pp. 333–389.
- [18]. Vaswani A. et al. (2017), “Attention Is All You Need”, *Advances in Neural Information Processing Systems*, 30.
- [19]. Xie J. et al. (2024), “TravelPlanner: A Benchmark for Real-World Planning with Language Agents”, *Proceedings of the 41st International Conference on Machine Learning*, pp. 54590–54613.